

方法	方法实现说明
MRVR	通过稀疏贝叶斯回归拟合输入到 SOH 的映射，并用参数后验给出预测分布
GP-ICE	通过高斯过程对输出函数建模，并借助核函数先验刻画预测不确定性
BMNN	通过 Bayes by Backprop 学习权重后验，再由参数采样形成预测分布
SACN	通过胶囊网络聚合时空特征，并借由特征响应的变化间接表征不确定性
DeNN	通过多个子模型的集成或融合统计预测分歧，以此近似不确定性
BDAE	通过随机失活下的多次前向传播形成预测集合，并用输出波动量化不确定性
SNGP	通过谱归一化稳定特征映射，并在输出端接高斯过程头近似后验分布

方法	方法实现说明
iTransformer	通过将变量维度作为建模对象，把多变量序列映射到反向注意力结构中
PatchTST	通过将长序列切分为 patch 并送入 Transformer，以局部片段建模全局依赖
TSMixer	通过纯 MLP 在时间维与通道维上交替混合特征，不依赖显式注意力
PINN	通过把物理约束写入损失函数，引导网络学习满足机理先验的退化映射
MambaLithium	通过状态空间选择性扫描机制建模长序列退化依赖
DeNN-bagging	通过自助采样训练多个子模型，并对输出结果做平均融合
DeNN-fusion	通过特征或预测级融合多个子模型，以提高跨样本稳定性
DeNN-voting	通过对子模型输出进行投票汇总，降低单模型偏置
LSTM-DA	通过 LSTM 提取时序特征，并配合域对齐模块缩小源域和目标域差异。
ConvMMD	通过卷积网络提取特征，并用 MMD 对齐不同域的分布。
DKTL	通过核映射增强特征可分性，并结合迁移学习实现跨域建模。
DDAN	通过域判别器对抗训练，使特征提取器学习域不变表示。
DR-Net	通过重构退化模式来增强特征表达，并抑制域间差异。
CRNN	通过卷积层提取局部模式，再用循环层建模时序依赖。
MAGNet	通过图结构传播退化关联，并在域间共享图表示。
iTransformer+	先在源域预训练，再直接在目标域上微调 iTransformer
PatchTST+	先在源域预训练，再直接在目标域上微调 PatchTST
TSMixer+	先在源域预训练，再直接在目标域上微调 TSMixer
PINN+	先在源域预训练，再直接在目标域上微调 PINN

方法	方法实现说明
VQVAE	通过离散码本对信号进行压缩重构，以生成更平滑的少数类样本
DCGAN	通过卷积生成器与判别器对抗训练，学习原始信号分布
QSCGAN	通过条件生成与判别联合约束，按类别条件生成目标信号
BearLLM	通过大语言模型把文本先验与信号表征结合起来生成诊断结果
MLMM	通过多模态表示对齐，将文本提示与振动信号联合建模
WDSN	通过显式检测分支区分已知类别输入与非预期输入
MDCC	通过校正模块修正检测偏差，并抑制非预期输入的误判
LLM-Check	通过语言模型生成的语义一致性来判断输入是否符合预期
MIND	通过多模态融合后的判别头区分已知类别与异常输入
SHalluDectect	通过结构化规则和检测器联合识别幻觉输入
LLM-OOD	通过大语言模型估计输入是否偏离训练分布
DA-TMLLM	通过关键 token 驱动的不确定性重加权，把文本推理与信号判别联合起来