

基于扩散增强可信多模态大语言模型的抗幻觉滚动机械故障诊断

摘要—大语言模型 (LLMs) 在机械系统故障诊断中表现出优异性能, 但其响应中潜在的事实性错误会削弱 LLMs 的可信度。这些事实性错误通常被称为幻觉, 阻碍了 LLMs 在安全关键环境中的部署。由于其自回归生成机制, 当受到嵌入在权重中的统计偏差或领域无关提示触发时, LLMs 可能会生成流畅但虚构的响应。此外, 大量形式正确但语义空洞的响应掩盖了局部幻觉的迹象。为解决这些问题, 我们提出了一种扩散增强可信多模态大语言模型 (DA-TMLLM)。首先, 我们设计了一个 ControlNet 引导的跨数据集条件扩散模型 (CGCDM), 通过注入可控语义引导和合成多样化样本来缓解统计偏差。其次, 我们设计了一个 TMLLM, 通过点二列相关分析和显著性检验来定位关键 token, 并设计关键 token 驱动的不确定性重加权策略, 以增强幻觉检测性能。第三, 我们设计了一个抗幻觉方案用于幻觉缓解和检测, 将 CGCDM 和 TMLLM 整合到一个统一的流程中, 并详细说明了拒绝领域无关提示的过程。在十一个数据集上获得的评估结果表明, 我们提出的 DA-TMLLM 在八个指标上始终优于十一个对比模型。

Index Terms—可信多模态大语言模型, 抗幻觉, 扩散增强, ControlNet, 关键 token 定位, 不确定性重加权策略。

I. 引言

型机械设备, 从高速列车到海上钻井平台, 对现代工业基础设施至关重要。滚动轴承作为机械的关键部件, 承担着减少摩擦和支撑载荷等多种重要功能, 通常在恶劣环境下运行 [1], [2]。因此, 对运行数据进行持续监测并快速诊断故障特征对于确保安全至关重要。得益于信号采集技术和人工智能的发展, 数据驱动的诊断方法已成为主流方法论, 能够从历史数据中自动得出诊断结果 [3], [4]。

近年来, 大语言模型 (LLMs) 因其优越性能已逐步取代传统深度学习模型 (CDLMs) 用于故障诊断 [5]。这些模型能够在多种工况下提供准确的诊断结果和维护建议。尽管取得了这些进展, 但最关键的一种失效模式, 即“幻觉”, 仍然是一个突出问题。幻觉指的是 LLM 生成的长文本回答中包含事实性错误的情况, 例如错误的诊断结果或不恰当的维护建议 [6], [7]。在实际部署中, 真实标签通常不可用, 因此难以确定 LLM 生成的响应

是否包含事实性错误。此类错误信息可能造成重大经济损失甚至危及人身安全。然而, 在消除 LLM 生成回答中的事实性错误和检测幻觉方面仍存在若干挑战。

统计偏差诱导的幻觉。工业滚动轴承在其大部分使用寿命中通常保持健康状态, 这使得轴承数据集本质上呈现不平衡的长尾分布。不平衡的训练集会使学习到的决策边界产生偏差, 并将统计偏差引入 LLMs, 导致它们倾向于多数类。因此, 大量的正常类别和任何相对频繁出现的故障模式主导了梯度更新, 成为偏差的主要来源。在推理过程中, 如果输入样本属于少数 (尾部) 类别, 模型仍然倾向于预测更常见的类别, 这可能导致对罕见但安全关键故障的漏报。

不期望输入诱导的幻觉。部署后, LLMs 可能会遇到不期望的输入, 例如来自以前未见过的旋转机械类型的传感器信号或其他领域无关的信号源。当面对此类输入时, LLMs 经常通过产生流畅但虚构的回答来产生幻觉, 而不是拒绝查询。这是因为当前的 LLMs 缺乏对其认知极限的明确意识, 不知道何时沉默才是适当的回应。此外, 如果不期望的输入与训练数据表现出强烈的语义重叠 (例如, 来自新型轴承但与已知数据相似的信号), LLM 可能变得过于自信并为此输入分配高后验概率。

序列级幻觉的隐蔽性。对于回答序列中的每个 token, 其后验概率主要受模型内部先验、语料级词频和局部句法模式的影响, 而不是该 token 与训练数据的匹配程度。因此, 当检测器仅基于 token 级后验进行判断时, 幻觉可能会逃脱检测。此外, 在评估整个回答序列时, 我们发现许多形式正确但语义空洞的短语, 例如“从提供的列表中最合适的轴承状态类型是”。这种语言冗余的存在往往会稀释幻觉内容。因此, 即使回答序列中存在幻觉, 幻觉量化指标仍可能给出正常值。

为解决这些问题, 我们提出了一种扩散增强可信多模态大语言模型 (DA-TMLLM)。首先, 我们设计了一个 ControlNet 引导的跨数据集条件扩散模型来缓解

统计偏差诱导的幻觉。其次，我们通过多个轴承数据集上的文本-信号对微调预训练 LLM，开发了一个 TMLLM。在开发的 TMLLM 基础上，我们识别关键 token 并设计关键 token 驱动的不确定性重加权策略来有效检测序列级幻觉。第三，我们设计了一个抗幻觉方案用于幻觉缓解和检测，将 CGCDM 和 TMLLM 整合到一个统一的流程中，并详细说明了拒绝不期望输入的过程。DA-TMLLM 的贡献如下：

- 1) 我们设计了一个 ControlNet 引导的跨数据集条件扩散模型。通过注入可控语义引导，该模型在保持语义一致性的同时增强了合成样本的多样性。
- 2) 我们通过定位关键 token 并设计关键 token 驱动的不确定性重加权策略，设计了一个可信多模态大语言模型，显著提高了 LLM 的幻觉检测性能。
- 3) 我们设计了一个抗幻觉方案，将 CGCDM 和 TMLLM 整合到一个统一的流程中，并结合不期望输入拒绝方法。该方案在缓解 LLM 幻觉的同时进一步提高了检测性能。
- 4) 在十一个数据集上获得的评估结果表明，DA-TMLLM 在八个指标上始终优于十一个对比模型。

本文结构如下。第二节回顾了与故障诊断和幻觉检测相关的 LLMs 和 CDLMs。第三节详细介绍了提出的用于抗幻觉故障诊断的 DA-TMLLM。第四节评估了 DA-TMLLM 的性能并展示了实验结果。第五节对本文进行总结。

II. 相关工作

在本节中，我们回顾了相关方法，包括 (1) 用于缓解统计偏差的 CDLMs 和 LLMs，(2) 用于拒绝不期望输入的 CDLMs 和 LLMs，以及 (3) 用于检测序列级幻觉的 LLMs。

A. 用于缓解统计偏差的 CDLMs 和 LLMs

在 [5] 中，H. Peng *et al.* 设计了一个跨数据集诊断 LLM，称为 BearLLM。在 [8] 中，X. Liu *et al.* 将脉冲电压嵌入引入扩散过程以实现可控振动合成。在 [9] 中，K. Zhou *et al.* 开发了一个平衡生成器-判别器架构用于诊断齿轮缺陷，称为 DCGAN。在 [10] 中，T. Han *et al.* 提出了一个混合网络，结合类别约束和对抗域正则化来捕获可迁移特征。在 [11] 中，M. Vu *et al.* 提出了一个双分支诊断框架，以提高稀疏标签场景下的故障分类准确率。在 [12] 中，W. Wan *et al.* 在生成器-判别器架构

中嵌入自注意力和谱归一化来增强火箭轴承数据，称为 QSCGAN。在 [13] 中，Q. Zheng *et al.* 结合退化阶段划分和向量量化增强来丰富退化特征，称为 VQVAE。

B. 用于拒绝不期望输入的 CDLMs 和 LLMs

在 [14] 中，C. Zhao *et al.* 采用三元组损失和边界自适应方法来学习紧凑特征和最优类别边界。在 [15] 中，Z. Zhu *et al.* 开发了一个对抗训练的开放集分类器来识别未知类别和域外样本。在 [16] 中，J. Long *et al.* 通过将元学习块与马氏距离相结合，开发了一个域泛化未见故障诊断方法，称为 MLMM。在 [17] 中，X. Zhang *et al.* 引入了一种域自适应方法，解耦私有和共享特征来诊断未见故障，称为 WDSN。在 [18] 中，B. Lu *et al.* 设计了一个基于对比嵌入的诊断策略，联合保留域特定和域不变特征，称为 MDCC。在 [19] 中，B. Liu *et al.* 对 LLaMA 系列 LLMs 进行不期望输入检测的基准测试，并使用各向同性嵌入设计了一个基于余弦距离的检测器，称为 LLM-OOD。

C. 用于检测序列级幻觉的 LLMs

在 [20] 中，G. Sriramanan *et al.* 设计了一个计算高效的检测器，利用模型的内部注意力图，称为 LLM-Check。在 [21] 中，J. Duan *et al.* 通过重加权 token 级和序列级相关性，开发了一种幻觉量化方法。在 [22] 中，T. Zhang *et al.* 引入了一个无需检索的检测器，通过 token 级不确定性来量化幻觉。在 [23] 中，P. Manakul *et al.* 提出了 SelfCheckGPT，通过采样多个黑盒 LLM 响应并测量它们的一致性来评估幻觉。在 [24] 中，W. Su *et al.* 提出了一个使用 LLMs 内部状态的实时无标注幻觉检测框架，称为 MIND。在 [25] 中，E. Quevedo *et al.* 提出了一个有监督方法，利用在资源高效的数值特征上训练的辅助检测器，称为 SHalluDetect。在 [6] 中，J. Li *et al.* 通过采样-过滤和标注开发了一个用于幻觉分析的基准。

然而，在提高诊断 LLMs 性能方面仍存在若干开放问题。首先，现有模型忽视了由数据集间差异和类别不平衡共同造成的复合统计偏差，经常将域特定特征误认为随机噪声。简单的基于扰动的增强通过生成强相关样本来进一步加剧这一问题，这些样本无法有效丰富少数类。其次，CDLMs 和 LLMs 倾向于低估与和训练数据共享高级语义的不期望输入相关的预测不确定性，从而降低诊断准确率。第三，由于生成文本中的语义冗余和




图 1: 所提出的 DA-TMLLM 的整体框架。(a) CGCDM(可控引导条件扩散模型) 注入语义引导以缓解统计偏差诱导的幻觉。(b) TMLLM(可信多模态大语言模型) 通过定位关键 token 并开发关键 token 驱动的不确定性重加权策略来检测序列级幻觉。(c) 基于 DA-TMLLM 设计了抗幻觉方案, 开发了训练和推理流程, 并详细说明了拒绝不期望输入的过程 (详见第III-C节)。

模型的过度自信, 现有检测器经常无法识别幻觉内容。为解决这些问题, 我们提出了 DA-TMLLM, 通过有效增强训练数据和准确量化生成回答的不确定性来检测和缓解 LLM 幻觉。

III. 方法

所提出的 DA-TMLLM 的整体框架如图 1所示。首先, 我们介绍设计的 ControlNet 引导跨数据集条件扩散模型 (CGCDM) 来缓解统计偏差诱导的幻觉。其次, 我们介绍可信多模态大语言模型, 包括微调、关键 token 定位和关键 token 驱动不确定性重加权策略的详细信息。第三, 我们介绍基于 DA-TMLLM 的抗幻觉方案。

A. ControlNet 引导的跨数据集条件扩散模型

为缓解数据集间差异, 我们提出了一种跨数据集标准化方法, 包括固定时长分割、长度对齐和尺度归一化。然后, 我们开发了条件扩散模型 (CDM) 的架构来合成振动信号。最后, 我们设计了一个 ControlNet 在反向扩散阶段注入可控语义引导。

1) 数据预处理的跨数据集标准化方法: 由于不同轴承数据集的传感器采样率、采集条件和轴承类型差异很大, 采集的信号在特征故障频率和幅度上存在差异。当这些异构信号直接输入扩散模型时, 模型倾向于将数据集间差异视为随机噪声, 阻碍其学习有效的联合分布。为解决这一问题, 我们提出了一种跨数据集标准化方法。

在传统的预处理方法中, 原始时域信号通常被分割成包含相同数据点数的固定长度样本。由于振动信号以不同的采样率采集, 固定长度分割方法会改变特征故障频率, 从而扩大数据集间差异。为缓解这一问题, 我们引入了固定时长分割方法, 第 m 个片段表示为

$$\mathbf{x}_o = \{ \mathbf{x}_r[i] \mid i = m\nu, m\nu + 1, \dots, (m+1)\nu - 1 \}, \quad (1)$$

其中 ν 是数据集特定的采样率, $\mathbf{x}_r$ 是原始信号。经过固定时长分割后, 来自不同数据集的片段需要进一步在长度和幅度上对齐以作为合适的网络输入。这通过依次应用离散傅里叶余弦变换和尺度归一化来实现, 分别表示为 $\text{DFCT}(\cdot)$ 和 $\text{SNorm}(\cdot)$ 。DFCT($\cdot$) 将时域片段转换为其频谱, 之后仅保留前 L_f 个频谱 bin, 其中 L_f 是预定义长度。为适应采样率的变化, 包含少于 L_f 个 bin

的频谱进行零填充, 而包含更多的则被截断。然后, 所得频谱的幅度通过 $\text{SNorm}(\cdot)$ 映射到区间 $[-1, 1]$ 。该预处理过程表示为

$$\mathbf{x}_v = \begin{cases} \text{SNorm}(\text{DFCT}(\mathbf{x}_o)[0:L_f]), & \ell \geq L_f, \\ \text{SNorm}(\text{Concat}(\text{DFCT}(\mathbf{x}_o), \mathbf{0}_{L_f-\ell})), & \ell < L_f, \end{cases} \quad (2)$$

其中 ℓ 是实际频谱 bin 数, $\text{SNorm}(\cdot)$ 表示为

$$\text{SNorm}(\mathbf{x}) = g \frac{\mathbf{x}}{\|\mathbf{x}\|_2}, \quad (3)$$

其中 $g = \rho\sqrt{L_f}$, ρ 是预定义的缩放因子。

2) *ControlNet* 引导的条件扩散: 我们采用基于扩散的增强模型, 同时促进训练稳定性和样本多样性, 它由前向扩散阶段和反向扩散阶段组成。为增强生成过程中的语义一致性, 我们设计了一个 *ControlNet*, 在每个反向扩散步骤将高级语义特征注入潜在特征。

在前向扩散过程中, 预处理后的 $\mathbf{x}_v$ 通过长度为 S 的马尔可夫链逐步添加噪声, 其中各向同性的高斯噪声在每一步 $s \in \{1, \dots, S\}$ 递增添加。第 s 步的加噪过程表示为

$$q(\mathbf{x}_v^{(s)} | \mathbf{x}_v^{(s-1)}) = \mathcal{N}(\sqrt{\alpha^{(s)}} \mathbf{x}_v^{(s-1)}, (1 - \alpha^{(s)})\mathbf{I}), \quad (4)$$

其中 $\mathbf{I}$ 是单位矩阵, $\alpha^{(s)}$ 是噪声缩放因子, $\alpha^{(s)} = 1 - \beta^{(s)}$, $\beta^{(s)}$ 由预定义的方差调度 ζ 指定。经过 S 步后, $\mathbf{x}_v^{(S)}$ 接近纯高斯样本分布。使用闭式累积, 整个前向扩散过程可表示为

$$q(\mathbf{x}_v^{(S)} | \mathbf{x}_v^{(0)}) = \mathcal{N}(\sqrt{\hat{\alpha}^{(S)}} \mathbf{x}_v^{(0)}, (1 - \hat{\alpha}^{(S)})\mathbf{I}), \quad (5)$$

其中 $\hat{\alpha}^{(S)} = \prod_{s=1}^S \alpha^{(s)}$ 。 $\mathbf{x}_v^{(S)}$ 作为后续反向扩散阶段的输入。

在反向扩散阶段, 初始潜在变量 $\mathbf{x}_v^{(S)} \sim \mathcal{N}(0, \mathbf{I})$ 由步感知去噪器 $\epsilon_{\theta_d}(\cdot)$ 迭代细化。在每个扩散步骤 s , 基于 UNet 的噪声预测网络接收三元组 $(\bar{\mathbf{x}}_v^{(s)}, s, \mathbf{c})$, 估计添加的高斯扰动, 并计算后验均值

$$\mu_{\theta_d}(\bar{\mathbf{x}}_v^{(s)}, s, \mathbf{c}) = \frac{\bar{\mathbf{x}}_v^{(s)} - \sigma^{(s)} \epsilon_{\theta_d}(\bar{\mathbf{x}}_v^{(s)}, s, \mathbf{c})}{\sqrt{\bar{\alpha}^{(s)}}}, \quad (6)$$

其中 $\bar{\alpha}^{(s)} = 1 - \bar{\beta}^{(s)}$, $\sigma^{(s)} = \sqrt{1 - \bar{\alpha}^{(s)}}$, $\mathbf{c}$ 是外部条件向量。 $\mathbf{c}$ 通过向噪声预测网络注入辅助信息, 在整个反向扩散阶段提供可控引导。然后从 $\mathcal{N}(\mu_{\theta_d}(\bar{\mathbf{x}}_v^{(s)}, s, \mathbf{c}), (\sigma^{(s)})^2 \mathbf{I})$ 采样新的潜在变量 $\bar{\mathbf{x}}_v^{(s-1)}$ 。对所有 $s = S, \dots, 1$ 重复此随机重建逐步抑制注入的噪




图 2: *ControlNet* 的架构。

声, 最终输出 $\bar{\mathbf{x}}_v^{(0)}$ 收敛到学习的数据分布, 从而产生真正的合成样本。

为向反向扩散阶段注入可控语义引导, 我们设计了一个 *ControlNet*, 将辅助知识嵌入为低维外部条件向量 $\mathbf{c}$ 。具体来说, 设计的 *ControlNet* 首先在标注的振动信号上进行预训练, 并优化以将每个原始信号映射到类别判别潜在表示。为构建对数据集间差异具有鲁棒性的外部条件向量, 我们采用三元组输入 $\mathbf{H}_v = [\mathbf{x}_v, \tilde{\mathbf{x}}_v, \mathbf{x}_{vr}] \in \mathbb{R}^{3 \times L_f}$, 其中 $\mathbf{x}_v$ 是生成的查询样本, $\tilde{\mathbf{x}}_v$ 是无故障信号样本, $\mathbf{x}_{vr} = \mathbf{x}_v - \tilde{\mathbf{x}}_v$ 是放大故障相关偏差的残差样本。如图 2 所示, *ControlNet* 的编码器由三个大核卷积通道组成, 随后是三个跨通道注意力块 (CCAB), 用于跨尺度融合特征。然后, 编码器的输出被送入一个两层全连接分类器, *ControlNet* 通过分类交叉熵损失进行训练。在扩散模型训练期间, *ControlNet* 的编码器和分类器权重, 表示为 θ_{enc} 和 θ_{cla} , 保持冻结。

在反向扩散阶段, 外部条件向量 $\mathbf{c}$ 通过多头注意力机制集成, 以确保生成样本的语义一致性。在第 s 个反向扩散步骤, 查询 ($\mathbf{Q}^{(s)}$)、键 ($\mathbf{K}^{(s)}$) 和值 ($\mathbf{V}^{(s)}$) 表示计算为

$$\mathbf{Q}^{(s)} = \mathbf{W}_Q \bar{\mathbf{x}}_v^{(s)}, \mathbf{K}^{(s)} = \mathbf{W}_K \tau(\mathbf{c}), \mathbf{V}^{(s)} = \mathbf{W}_V \tau(\mathbf{c}), \quad (7)$$

其中 $\mathbf{W}_Q$ 、 $\mathbf{W}_K$ 和 $\mathbf{W}_V$ 是可学习的线性投影矩阵, $\tau(\cdot)$ 表示一个编码器, 将 $\mathbf{c}$ 和 $\bar{\mathbf{x}}_v^{(s)}$ 投影到相同维度的特征

空间。然后注意力输出计算为

$$\mathbf{A}^{(s)} = \text{Softmax}\left(\frac{\mathbf{Q}^{(s)}(\mathbf{K}^{(s)})^\top}{\sqrt{d_k}}\right)\mathbf{V}^{(s)}, \quad (8)$$

其中 d_k 是键的维度。在多头注意力框架中，注意力过程在多个头上独立应用。每个头的输出然后被拼接并通过线性变换投影以产生最终输出，表示为

$$\text{MHA}(\bar{\mathbf{x}}_v^{(s)}, \mathbf{c}) = \mathbf{W}_o[\mathbf{A}_1^{(s)}; \dots; \mathbf{A}_{N_h}^{(s)}], \quad (9)$$

其中 $\mathbf{W}_o$ 是输出投影矩阵， N_h 表示注意力头的数量。通过以这种方式集成外部条件向量 $\mathbf{c}$ ，我们有效地将语义上下文注入反向扩散过程的每一步。

设计的 ControlNet 引导跨数据集条件扩散模型的损失函数可表示为

$$L^{(s)} = \mathbb{E}_{s \sim [1, S], \mathbf{x}_v^{(s)}, \mathbf{c}^{(s)}} [\text{Huber}(\|\mathbf{r}^{(s)}\|)], \quad (10)$$

其中 $\mathbf{r}^{(s)} = \|\epsilon^{(s)} - \epsilon_{\theta_d}(\bar{\mathbf{x}}_v^{(s)}, s, \mathbf{c})\|$ ， $\text{Huber}(\cdot)$ 是 Huber 损失。Huber 损失衰减大点态残差的影响，因此对信号样本之间可能存在的相位偏移更加鲁棒，其展开式为

$$\text{Huber}(r^{(s)}) = \begin{cases} \frac{1}{2} (r^{(s)})^2, & r^{(s)} < \lambda, \\ \lambda (r^{(s)} - \frac{\lambda}{2}), & \text{otherwise}, \end{cases} \quad (11)$$

其中 λ 是 $\text{Huber}(\cdot)$ 的转移阈值。

B. 可信多模态大语言模型

TMLLM 旨在跨多个数据集提供可信的诊断结果和分析。在 TMLLM 中，多模态大语言模型通过在文本-信号对上微调预训练 LLM 来开发。为获得可信回答，我们通过计算点二列相关系数并进行显著性检验，定位能量异常下降的关键 token。此外，我们设计了一个关键 token 驱动的不确定性重加权策略来量化 LLM 回答中的不确定性。

1) 基于文本-信号对微调 LLM: 由于最近的预训练 LLM 针对离散文本 token 进行优化，无法原生处理振动信号，我们引入了一个双分支 tokenizer-编码器块，将振动信号样本和相应的文本描述转换为信号特定和 token 特定的特征。模态特定特征随后通过文本-信号对齐块进行对齐，整个模型被微调以最大化跨模态对齐。

在开发的双分支 tokenizer-编码器块中，编码器与 ControlNet 共享权重 θ_{enc} 。令 $\mathbf{x}_g$ 为合成样本，编码器分支的输入可表示为 $\mathbf{H}_g = [\mathbf{x}_g, \tilde{\mathbf{x}}_g, \mathbf{x}_{gr}] \in \mathbb{R}^{3 \times L_f}$ ，其中 $\mathbf{x}_g$ 是查询样本， $\tilde{\mathbf{x}}_g$ 是无故障信号样本， $\mathbf{x}_{gr} = \mathbf{x}_g - \tilde{\mathbf{x}}_g$

是放大故障相关偏差的残差样本。该编码器为每个输入产生信号特定特征。令 $\mathbf{D} = \{k_1, \dots, k_{N_c}\}$ 为短文本故障描述的集合，每个故障类别一个描述，其中 N_c 表示类别数。此外，TMLLM 的多模态输入通过融合 $\mathbf{H}_g$ 和 $\mathbf{T}$ 获得，表示为 $\mathbf{M}_g = \{\mathbf{H}_g, \mathbf{T}\}$ 。在 tokenizer 分支中，我们将 $\mathbf{D}$ 通过 LLM 的原生 tokenizer $\text{Tok}(\cdot)$ 和嵌入层 $\text{Emb}(\cdot)$ 以获得 token 特定特征序列，表示为 $\mathbf{E} = \text{Emb}(\text{Tok}(\mathbf{D})) \in \mathbb{R}^{\gamma \times N_c \times h}$ ，其中 h 是 $\text{Emb}(\cdot)$ 的隐藏大小， γ 是 token 特定特征的最大长度。如图 1 所示，双分支 tokenizer-编码器块的权重在 LLM 微调期间保持冻结。

为弥合信号特定/token 特定特征与 LLMs 之间的差距，我们开发了一个可训练的文本-信号对齐块，将信号特定和 token 特定特征融合为适合 LLM 输入的语言 token。对齐块实现为一个三层线性多层感知器。我们使用 ControlNet 的先验权重和 token 特定特征的组合来初始化该对齐模块。具体来说，前两个线性层的权重，表示为 θ_{l_1} 和 θ_{l_2} ，使用 ControlNet 预训练分类器的权重 θ_{cla} 进行初始化。此外，我们展平 $\mathbf{E}$ 的最后两个维度，并将所得矩阵用作 l_3 的权重，表示为 $\theta_{l_3} = \text{reshape}(\mathbf{E}, (\gamma, N_c h)) \in \mathbb{R}^{\gamma \times N_c h}$ 。这样， θ_{l_3} 的第 i 行编码了第 i 个故障描述的 token 级嵌入，提供了从信号特定特征到语言 token 的语义投影。最后，文本-信号对齐块将语言 token 嵌入预定义的提示模板中，并输出 $\mathbf{x}_{pt}$ 作为 LLM 的输入。文本-信号对齐块的权重表示为 $\theta_{\text{ts}} = \{\theta_{l_1}, \theta_{l_2}, \theta_{l_3}\}$ ，预训练 LLM 的权重表示为 θ_{llm} 。为了在下游任务上微调文本-信号对齐块和 LLM 的权重，我们采用使用低秩适配 (LoRA) [26] 的参数高效方法。

2) 关键 token 定位: 为解决序列级幻觉的隐蔽性问题，我们联合考虑自回归生成规则和诊断特定特征。我们假设某些关键 token 充当哨兵，发出即将发生不确定性的信号。然后，我们在保留语料库上进行点二列相关计算来评估该假设，比较幻觉回答之前 token 的能量与事实回答中匹配 token 的能量。最后，我们进行显著性检验以表明能量的下降是由不期望输入引起的，而非随机波动。显著性检验返回 $p = 3.2779 \times 10^{-28}$ ，拒绝了低能量 token 随机出现的零假设。

在生成诊断回答时，LLMs 通过一次预测一个 token 来自回归生成回答，并为下一个 token 产生词汇表上的

概率分布, 可表示为

$$P(\text{Token}_k = w \mid \text{Token}_{<k}) = \frac{\exp(\text{Proj}(\mathbf{a}_k)_w)}{\sum_{w' \in \mathcal{V}} \exp(\text{Proj}(\mathbf{a}_k)_{w'})}, \quad (12)$$

其中 Token_k 是生成步骤 k 的输出 token, $\text{Token}_{<k}$ 是 k 之前生成的整个诊断回答 token 序列, $\mathcal{V}$ 是 LLM 的原生词汇表集合, w 是从 $\mathcal{V}$ 中抽取的单个 token, $\mathbf{a}_k$ 是 k 处的隐藏状态向量, $\text{Proj}(\cdot)$ 是可学习的线性变换函数, $\sum_{w \in \mathcal{V}} P(\text{Token}_k = w \mid \text{Token}_{<k}) = 1$ 。当许多 token 具有较低概率时, 表明下一个 token 预测的不确定性较高。此外, token 的负对数似然 (NLL) 可解释为 token 级能量, 表示为

$$\text{NLL}(\text{Token}_k = w) = -\log \frac{\exp(\text{Proj}(\mathbf{a}_k)_w)}{\sum_{w' \in \mathcal{V}} \exp(\text{Proj}(\mathbf{a}_k)_{w'})}, \quad (13)$$


其中 $\text{NLL}(\cdot)$ 是 token 能量函数。低 NLL 表示模型为该 token 分配了高概率, 而高 NLL 表示 LLM 在生成此 token 时存在歧义。

基于这一分析, 我们的假设是当 LLM 首次输出错误的故障分类结果时, token 能量在错误分类 token 周围发生异常变化。这一假设基于两个事实。首先, 当模型在其回答中输出错误的故障类别时, 这是一种严重的幻觉。其次, 上述关于幻觉与能量关系的分析表明, 局部幻觉通常伴随着错误附近 token 能量的异常变化。

为验证我们的假设, 我们首先构建一个保留语料库。我们使用 MBHM 数据集 [5] 的样本作为正常输入, 使用 MaFaulDa 数据集 [27] 的样本作为不期望输入, 并使用 Qwen-2 1.5B 模型 [28] 作为 LLM。我们为正常输入生成 N_{nor} 个回答, 为不期望输入生成 N_{un} 个回答。此外, 在首次误分类发生的 token 为中心的 $\pm L_{\text{win}}$ token 窗口内计算 token 能量, 该 token 表示为 Token_δ 。然后, 计算点二列相关系数, 表示为 r_{pb} , 以检验 token 能量与相应输入之间的关系。点二列相关是适用于特殊情况的 Pearson 相关, 量化二进制输入类型与连续 token 能量之间的相关性。 r_{pb} 表示为

$$r_{\text{pb}} = \frac{\mu_{\text{nor}} - \mu_{\text{un}}}{\sigma_{\text{total}}} \sqrt{\frac{N_{\text{nor}} N_{\text{un}}}{(N_{\text{nor}} + N_{\text{un}})^2}}, \quad (14)$$

其中 μ_{nor} 是正常输入回答的平均 token 能量, σ_{total} 是所有回答 token 能量的标准差。最后, 我们进行显著性检验来评估 r_{pb} 的结果, 以表明能量的上升是由不期望



Tab. Results of Significance Test

Position	$\delta-3$	$\delta-2$	$\delta-1$	δ	$\delta+1$	$\delta+2$	$\delta+3$
Value	6×10^{-1}	2×10^{-21}	3×10^{-28}	2×10^{-19}	2×10^{-1}	5×10^{-58}	3×10^{-25}

图 3: 在以 Token_δ 为中心的 $\pm L_{\text{win}}$ 范围内, 二进制输入类型与 token 能量序列之间的点二列相关系数 r_{pb} 和双侧 p 值 $p_{\text{two-sided}}$ 。基于理论基础和统计证据, 选择 $\text{Token}_{\delta-1}$ 作为不期望输入检测的关键 token。

输入引起的, 而非随机波动。系数 r_{pb} 被转换为 t 统计量, 表示为

$$t = r_{\text{pb}} \sqrt{\frac{(N_{\text{nor}} + N_{\text{un}}) - 2}{1 - r_{\text{pb}}^2}}, \quad \text{df} = (N_{\text{nor}} + N_{\text{un}}) - 2, \quad (15)$$

其中 df 是自由度。此外, 双侧 p 值, 表示为 $p_{\text{two-sided}}$, 然后从学生 t 分布的累积分布函数 (CDF) 中获得, 表示为

$$p_{\text{two-sided}} = 2[1 - F_{t_{\text{df}}}(|t|)] = 2P(T_{\text{df}} \geq |t|), \quad (16)$$

其中 $F_{t_{\text{df}}}(\cdot)$ 是自由度为 df 的学生 t 分布的 CDF, T_{df} 是服从该分布的随机变量。

如图 3 所示, 我们在以 Token_δ 为中心的 $\pm L_{\text{win}} = 3$ 范围内计算二进制输入类型与 token 能量序列之间的 r_{pb} 和 $p_{\text{two-sided}}$ 。在 token $\text{Token}_{\delta-1}$ 处, 观察到大的效应量, 其中 $|r_{\text{pb}}| > 0.5$ 且 $r_{\text{pb}} < -0.5$ 。该观察表明 token 能量的异常下降对不期望输入具有高度预测性。此外, 显著性检验返回 $p = 3 \times 10^{-28}$, 拒绝了低能量 token 随机出现的零假设。从理论角度来看, 不期望输入倾向于在 Token_δ 周围诱导局部能量扭曲。因为 $\delta-1$ 紧邻 δ , 它对不期望输入的最早迹象本质上更具响应性, 与统计证据一致。因此, 我们采用 $\text{Token}_{\delta-1}$ 作为不期望输入检测的关键 token, 尽管 $\text{Token}_{\delta+2}$ 具有更高的相关性, 但将其省略。

3) 关键 token 驱动的不确定性重加权策略: 为量化 LLM 输出的不确定性并构建 TMLLM, 我们提出了




图 4: 关键 token 驱动的不确定性重加权策略示意图。

关键 token 驱动的不确定性重加权策略 (KTURS)。所提出的策略采用 token 级能量作为不确定性量化指标, 并为与指定关键 token 表现出更强相关性的 token 分配更大的权重。

对于关于多模态输入 x_{pt} 的 LLM 输出 $\hat{y}_g$, 表示为 $\hat{y}_g = \{Token_1, Token_2, \dots, Token_{N_t}\}$, 其中 N_t 是输出长度。我们首先为每个 token $Token_k (1 \leq k \leq N_t)$ 计算归一化能量分数, 表示为

$$NLL(Token_k) = \frac{NLL(Token_k)}{\sum_{j=1}^{N_t} NLL(Token_j)}. \quad (17)$$

然后, 我们根据 r_{pb} 通过放大关键 token 的权重来推导 token 级不确定性, 表示为

$$UT(Token_k; \omega, r_{pb}) = [1 + (\omega r_{pb} - 1) \mathbf{1}_{\{k=\delta-1\}}] \tilde{NLL}(Token_k), \quad (18)$$

其中 $\mathbf{1}_{\{k=\delta-1\}}$ 当 token 索引 $k = \delta - 1$ 时为 1, 否则为 0, ω 是用于校准 token 级不确定性程度的系数。最后, LLM 输出的不确定性可表示为

$$UA(\hat{y}_g) = \sum_{k=1}^{N_t} [1 + (\omega r_{pb} - 1) \mathbf{1}_{\{k=\delta-1\}}] \tilde{NLL}(Token_k). \quad (19)$$

如图 4 所示, 原始能量分数首先被归一化为不确定性分布 $\tilde{NLL}(Token_k)$, 然后关键 token $Token_\delta$ 的不确定性被因子 ω 放大, 最后通过对所有 N_t 个 token 的 token 级不确定性求和获得序列级不确定性 $UT(Token_k; \omega, r_{pb})$ 。

C. 基于 DA-TMLLM 的抗幻觉方案

为缓解和检测 LLM 幻觉, 所提出的抗幻觉方案将基于扩散的增强和可信多模态大语言模型整合到一个统一的流程中。

为缓解统计偏差诱导的幻觉, ControlNet 引导的跨数据集条件扩散模型被设计用于产生平衡且语义对齐的合成数据。原始样本和合成样本随后被融合并用于微调可信多模态大语言模型。训练阶段的流程总结在算法 1 中。在输入任何测试样本之前, 我们在仅包含正常样本的验证集上评估不确定性分数的均值和方差, 表示为 μ_{val} 和 σ_{val} 。这使我们能够定义不确定性阈值的上下界, $\psi_{lower} = \mu_{val} - \sigma_{val}$ 和 $\psi_{upper} = \mu_{val} + \sigma_{val}$, 它们共同形成决策区间 $[\psi_{lower}, \psi_{upper}]$ 。此外, 我们定位关键 token 并设计关键 token 驱动的不确定性重加权策略。推理阶段的流程总结在算法 2 中。

IV. 实验

本节对 DA-TMLLM 进行了全面评估, 在十一个数据集和七个评估指标上将其与九个基线方法进行了基准比较。首先, 我们在幻觉易发场景下评估 DA-TMLLM 的性能, 并评估数据增强对少数类的有效性。其次, 进行消融研究以量化每个关键组件的贡献。第三, 我们分析 DA-TMLLM 性能对不同超参数的敏感性。

A. 实验设置

为了在幻觉易发场景下对 DA-TMLLM 与对比模型进行基准测试, 我们采用两类数据集: 域特定数据集和不期望数据集。不期望数据集仅在测试阶段使用, 用于构建不期望测试子集, 以量化模型拒绝不期望输入的能力。域特定数据集由多个轴承数据集组成, 被划分为训练集、验证集和域特定测试子集。此外, 我们将域特定测试子集和不期望测试子集合并为复合测试集, 以对模型的抗幻觉性能进行统一评估。域特定数据集包括九个轴承数据集: PU [1]、JNU [29]、CWRU [30]、JUST [2]、DIRG [31]、HIT [4]、IMS [32]、MFPT [33] 和 XJTU [34], 所有这些数据集都包含在 MBHM 仓库 [5] 中。表 I 总结了本研究中使用的九个域特定轴承数据集, 详细列出了各自的故障位置类别和样本数量。不期望数据集由 UP [35] 和 MaFaulDa [27] 数据集组成。

为评估模型对由统计偏差引起的幻觉的鲁棒性, 我们在训练和验证期间遵循 [36] 的极端类别不平衡设置, 其中最大类和最小类之间的比率超过 100。此外, 我们

表 I: 数据集概览

故障位置	PU [1]	JNU [29]	CWRU [30]	JUST [2]	DIRG [31]	HIT [4]	IMS [32]	MFPT [33]	XJTU [34]	总样本数	训练样本数
无故障 (FF)	1918	900	70	10932	1020	3816	43176	18	11014	72864	10000
轻微内圈故障 (MiIR)	954	-	310	-	1020	-	812	-	64	3160	2736
中度内圈故障 (MoIR)	633	900	296	11124	1020	4032	-	21	28	18054	10000
严重内圈故障 (SIR)	- ¹	-	350	-	1020	-	-	-	232	1602	345
轻微滚珠故障 (MiB)	-	-	310	-	1020	-	-	-	30	1360	45
中度滚珠故障 (MoB)	-	900	310	10956	1020	-	1000	-	60	14246	10000
严重滚珠故障 (SB)	-	-	350	-	1020	-	312	-	356	2038	1005
轻微外圈故障 (MiOR)	2223	-	918	-	-	-	575	-	284	4000	4620
中度外圈故障 (MoOR)	1588	900	340	10974	-	1800	447	39	260	16348	10000
严重外圈故障 (SOR)	-	-	678	-	-	-	158	-	1008	1844	1764

¹ 破折号 (-) 表示该数据集中不存在相应的故障位置类别。

采用平衡的域特定测试子集，使每个类别对诊断性能的贡献相等。MaFaulDa 数据集包含与域特定数据集具有高语义相似性的轴承振动信号。相比之下，UP 数据集包含水下螺旋桨故障信号，在运行环境和信号特征上都表现出显著的域偏移。为评估模型对不同程度相似性不期望输入诱导幻觉的抵抗能力，定义了三种类型的复合测试场景。场景 1 使用由域特定子集与 UP 组合形成的测试集。场景 2 用 MaFaulDa 替换 UP，确保与训练数据集的高语义相似性。场景 3 采用由域特定子集、UP 和 MaFaulDa 组成的复合测试集，产生混合域评估设置。

所有评估均在使用 NVIDIA RTX 4090 GPU 的工作站上使用 PyTorch 进行。15 亿参数的 Qwen2 [28] 模型作为基础 LLM，采用 LoRA 技术 [26] 对 TMLLM 进行微调。DA-TMLLM 的超参数总结在表 II 中。此外，数据集特定的采样率 ν 在相应的数据集文档中提供。使用八个指标对 DA-TMLLM 和对比模型进行全面评估，其中 $\uparrow$ 表示较大值表示性能更优， $\downarrow$ 表示较低值更优。

域特定准确率 (DS-ACC, $\uparrow$) 计算正确诊断的故障类型与来自域特定测试子集的样本总数的比率。

总体准确率 (G-ACC, $\uparrow$) 呈现在结合域特定和不期望样本的混合测试集上的总体诊断准确率。

受试者工作特征曲线下面积 (AUROC, $\uparrow$) 测量域特定样本和不期望样本之间的可分离性，较高值表示更强的分离能力。

95% 召回率下的误报率 (FAR@95, $\downarrow$) 是当检测器

表 II: 超参数设置

符号	描述	值
L_f	样本长度	2400
ρ	SNorm($\cdot$) 的缩放因子	0.01
S	扩散步数	10
ζ	扩散模型的噪声调度器	<i>Linear</i>
N_h	注意力头数	4
N_c	样本类别数	10
λ	Huber($\cdot$) 的转移阈值	1
N_t	输出 token 的最大长度	2048
$\mathcal{M}_{tune}$	微调的目标模块	<i>all_linear</i>
r_{LoRA}	LoRA 微调的秩	4
L_{win}	token 窗口长度	± 3
ω	关键 token 的校准系数	50
n_{diff}	扩散的批次大小	32
n_{tune}	微调的批次大小	1 per GPU
N_{dm}	CGCDM 的训练轮数	100
N_{llm}	TMLLM 的训练轮数	50
n_{lr}	学习率	1×10^{-4}
n_{dr}	Dropout 率	0.1

达到 95% 不期望召回率时，被错误分类为不期望样本的域特定样本比例。

精确率-召回率曲线下面积 (AUPR, $\uparrow$) 强调域特定准确率，较高值表示更干净地拒绝不期望样本。

均方根误差 (RMSE, $\downarrow$) 通过测量合成信号与实际信号之间点态差异的二次均值来呈现生成质量。

峰值信噪比 (PSNR, $\uparrow$) 通过测量最大信号功率与损坏噪声功率之比来量化重建质量。

频谱余弦相似度 (FSCS, $\uparrow$) 通过计算幅度谱的相似度来表达合成信号与实际信号之间的生成质量。

表 III: 抗幻觉故障诊断实验结果¹

场景	场景 1 ²					场景 2 ³					场景 3 ⁴				
指标	DS-ACC	G-ACC	AUROC	FAR@95	AUPR	DS-ACC	G-ACC	AUROC	FAR@95	AUPR	DS-ACC	G-ACC	AUROC	FAR@95	AUPR
VQVAE	78.89%	72.82%	0.6812	0.8028	0.1490	78.89%	72.82%	0.5832	1.0000	0.0956	78.89%	67.62%	0.6322	0.8083	0.2047
DCGAN	85.56%	78.97%	0.4596	0.7083	0.0678	85.56%	78.97%	0.7306	0.4861	0.1468	85.56%	73.33%	0.5951	0.6917	0.1730
QSCGAN	83.89%	77.44%	0.5393	1.0000	0.0942	83.89%	77.44%	0.6821	0.6194	0.1261	83.89%	71.90%	0.6107	0.9139	0.1896
BearLLM	88.33%	81.54%	0.5893	0.9083	0.0983	88.33%	81.54%	0.7328	0.7472	0.2326	88.33%	75.71%	0.6610	<u>0.2545</u>	0.8778
MLMM	<u>89.17%</u>	<u>88.46%</u>	0.9622	0.2722	0.8660	89.17%	<u>86.92%</u>	0.9181	0.2833	0.7464	<u>89.17%</u>	<u>86.43%</u>	<u>0.9401</u>	0.2722	0.8483
WDSN	71.94%	74.10%	0.9795	0.1000	0.9983	71.94%	72.56%	0.8139	0.9000	0.9806	71.94%	74.29%	0.8888	0.4667	<u>0.9790</u>
MDCC	77.50%	79.23%	<u>0.9867</u>	<u>0.0333</u>	<u>0.9989</u>	77.50%	81.54%	0.7636	0.9000	<u>0.9749</u>	77.50%	78.81%	0.8722	0.5333	0.9735
LLMCheck	85.28%	73.33%	0.5744	0.7000	0.5189	85.28%	71.03%	0.5567	0.6667	0.5641	85.28%	76.19%	0.6544	0.7500	0.5707
MIND	85.00%	82.05%	0.8611	0.6333	0.8641	85.00%	82.82%	0.8889	<u>0.2667</u>	0.8310	85.00%	78.57%	0.8206	0.4500	0.8088
SHalluDetect	92.78%	85.64%	0.6066	1.0000	0.9318	92.78%	85.64%	0.6289	0.7333	0.9445	92.78%	79.52%	0.5112	0.8333	0.8581
LLM-ODD	85.28%	77.69%	0.8646	0.8038	0.8222	85.28%	78.46%	<u>0.9615</u>	0.8870	0.4222	85.28%	78.10%	0.9131	0.8688	0.6944
DA-TMLLM	92.78%	93.33%	1.0000	0.0000	1.0000	92.78%	92.82%	0.9860	0.0028	0.9092	92.78%	93.57%	0.9942	0.0000	0.9887

¹ 最佳结果: **粗体**; 次佳结果: 下划线。² 场景 1 使用由域特定子集与 UP 组合形成的测试集。³ 场景 2 用 MaFaulDa 替换 UP, 确保与训练数据集的高语义相似性。⁴ 场景 3 采用由域特定子集、UP 和 MaFaulDa 组成的复合测试集, 产生混合域评估设置。

B. 性能对比

我们在 MBHM、MaFaulDa 和 UP 数据集上评估了 DA-TMLLM 和十一个基线模型的抗幻觉故障诊断性能。表 III 展示了使用五个指标 (包括 DS-ACC、G-ACC、AUROC、FAR@95 和 AUPR) 在场景 1、2 和 3 中的结果。实验结果突显了 DA-TMLLM 的优越性, 它大幅且始终优于所有基线模型。在场景 1 中, 我们的模型在 DS-ACC 和 G-ACC 上分别比次佳模型提高了 4.05% 和 5.51%, 同时达到了理想的检测性能。这种优势在场景 3 的复杂混合域设置中得以保持, 再次在所有指标上取得了最先进的结果。唯一的例外是在场景 2 中, DA-TMLLM 在 AUPR 指标上略逊于 WDSN。尽管如此, 它仍在 G-ACC 上领先, 并在 FAR@95 上实现了相比最近基线 98.95% 的降低。平均而言, 相比最强竞争对手, G-ACC 提高了 6.85%, FAR@95 降低了 99.65%, DA-TMLLM 有效展示了其同时执行高精度故障诊断和

鲁棒幻觉检测的能力。相比之下, 基线模型表现出局限性。VQVAE、DCGAN、QSCGAN 和 BearLLM 由于缺乏明确的幻觉检测能力, 无法可靠地区分域特定输入和不期望输入, 这从 DS-ACC 到 G-ACC 的急剧下降以及较差的 AUROC 和 AUPR 分数可以看出。在具有检测能力的基线中, 可以观察到性能权衡。CDLMs (包括 MLMM、WDSN 和 MDCC) 通常在幻觉检测方面更为擅长。相反, 基于 LLM 的方法 (包括 LLMCheck、MIND、SHalluDetect 和 LLM-ODD) 在分布内分类方面表现出优越性。两类模型都倾向于将有效的域特定样本错误分类为不期望样本, 同时在处理被标记为幻觉的输入时过于保守。

为说明跨不同决策阈值的抗幻觉诊断性能, 我们绘制了受试者工作特征 (ROC) 曲线和精确率-召回率 (PR) 曲线, 如图 5 所示。这些可视化从图形上证实了表 III 中的定量发现。DA-TMLLM 的 ROC 曲线在所有场

Algorithm 1 扩散增强可信多模态大语言模型的训练流程

输入: 预处理数据集 $\mathcal{D}_{\text{real}} = \{(\mathbf{x}_v, y)\}$, 权重 θ_{enc} 、 θ_d 、 θ_{cla} 、 θ_{ts} 和 θ_{llm} , 超参数 S 、 N_{dm} 、 N_{llm} 和 N_{aug} , 响应文本 y_g

输出: 训练好的 CGCDM θ_d^* , 微调后的 TMLLM θ_{ts}^* 、 θ_{llm}^*

阶段 1: 训练 ControlNet 引导的 CDM

```

1: for epoch = 1 to  $N_{\text{dm}}$  do ▷ 训练轮数  $N_{\text{dm}}$ 
2:   for all  $(\mathbf{x}_v, y) \sim \mathcal{D}_{\text{real}}$  do
3:      $\mathbf{x}_v^{(S)} \leftarrow \text{ADDNOISE}(\mathbf{x}_v, S)$ 
4:      $L^{(s)} \leftarrow \|\epsilon - \epsilon_{\theta_d}(\mathbf{x}_v^{(s)}, y, s)\|_2^2$ 
5:      $\theta_d^* \leftarrow \theta_d - \eta_{\theta_d} \nabla_{\theta_d} L^{(s)}$ 
6:   end for
7: end for

```

阶段 2: 生成增强样本

```

8: for  $n = 1$  to  $N_{\text{aug}}$  do ▷ 增强样本数  $N_{\text{aug}}$ 
9:    $\mathbf{x}_v^{(S)} \sim \mathcal{N}(\mathbf{0}, I)$ 
10:  for  $s = S$  downto 1 do
11:     $\mathbf{c} \leftarrow \text{CONTROLNET}(\theta_{\text{enc}}, \theta_{\text{cla}})$ 
12:     $\mu \leftarrow \text{POSTERIORMEAN}(\mathbf{x}_v^{(s)}, s, \mathbf{c}, \theta_d^*)$ 
13:     $\bar{\mathbf{x}}_v^{(s-1)} \sim \mathcal{N}(\mu, (\sigma^{(s)})^2 I)$ 
14:  end for
15:   $\mathcal{D}_{\text{syn}} \leftarrow \mathcal{D}_{\text{syn}} \cup \{\bar{\mathbf{x}}_v^{(0)}\}$ 
16: end for
17:  $\mathcal{D}_{\text{aug}} \leftarrow \mathcal{D}_{\text{real}} \cup \mathcal{D}_{\text{syn}}$ 

```

阶段 3: 微调可信多模态大语言模型

```

18: 初始化  $\mathbf{x}_g \leftarrow \bar{\mathbf{x}}_v$ 
19: for epoch = 1 to  $N_{\text{llm}}$  do ▷ 训练轮数  $N_{\text{llm}}$ 
20:   for all  $(\mathbf{x}_g, y_g) \sim \mathcal{D}_{\text{aug}}$  do
21:      $\mathbf{x}_{pt} \leftarrow \text{ALIGNBLOCK}(\mathbf{x}_g)$ 
22:      $\hat{y}_g \leftarrow \text{TMLLM}(\mathbf{x}_{pt})$ 
23:      $\theta_{\text{ts}}^*, \theta_{\text{llm}}^* \leftarrow \text{LoRA}(\hat{y}_g, y_g)$ 
24:   end for
25: end for
26: return  $\theta_d^*$ 、 $\theta_{\text{ts}}^*$ 、 $\theta_{\text{llm}}^*$ 

```

景中都始终占据理想的左上角, 表明卓越的可分离性, 这与其 AUROC 和 FAR@95 分数一致。类似地, PR 曲线显示我们的模型最接近右上角, 在召回率范围内保持极高的精确率, 证实了其 AUPR 值。相比之下, 基线模型的曲线明显较差, 强化了 DA-TMLLM 实现更

Algorithm 2 基于关键 token 驱动不确定性重加权策略的推理流程

输入: 测试集 $\mathcal{D}_{\text{test}}$, 窗口长度 L_{win} , TMLLM 权重 θ_{ts}^* 、 θ_{llm}^* , 校准系数 ω , 关键 token 索引 $\delta - 1$, 不确定性阈值 ψ

```

1: for all  $\mathbf{x}_{\text{test}} \sim \mathcal{D}_{\text{test}}$  do
2:    $\hat{y}_{\text{test}} \leftarrow \text{TMLLM}(\theta_{\text{ts}}^*, \theta_{\text{llm}}^*; \mathbf{x}_{\text{test}})$ 
3:    $\hat{y}_{\text{test}} = \{Token_1, \dots, Token_{N_t}\}$ 

```

阶段 1: Token 级归一化

```

4: for  $k = 1$  to  $N_t$  do
5:    $\text{NLL}_k \leftarrow -\log P(Token_k | Token_{<k})$ 
6: end for
7:  $\tilde{\text{NLL}}_k \leftarrow \text{NLL}_k / \sum_{j=1}^{N_t} \text{NLL}_j$ 

```

阶段 2: 关键 token 重加权

```

8: for  $k = 1$  to  $N_t$  do
9:    $\text{UT}_k \leftarrow \left[1 + (\omega r_{\text{pb}} - 1) \mathbf{1}_{\{k=\delta-1\}}\right] \tilde{\text{NLL}}_k$ 
10: end for

```

阶段 3: 序列级聚合

```

11:  $\text{UA}(\hat{y}_{\text{test}}) \leftarrow \sum_{k=1}^{N_t} \text{UT}_k$ 

```

阶段 4: 决策

```

12: if  $\text{UA}(\hat{y}_{\text{test}}) \notin [\psi_{\text{lower}}, \psi_{\text{upper}}]$  then
13:   拒绝  $\mathbf{x}_{\text{test}}$  ▷ 检测到幻觉
14: else
15:   输出  $\hat{y}_{\text{test}}$ 
16: end if
17: end for

```

鲁棒和可靠幻觉检测的结论。

如图 6 所示, 我们进一步利用 DA-TMLLM 和基线模型的扩展混淆矩阵来量化抗幻觉诊断中的两种关键错误类型, 即错误接受不期望输入和错误拒绝域特定样本。扩展混淆矩阵联合呈现了场景 3 的幻觉检测结果和域特定分类结果。DA-TMLLM 的混淆矩阵非常清晰, 以对角线为主导, 非对角线值最小。它正确拒绝了 98% 的不期望输入, 且没有拒绝任何域特定样本。然而, 基线模型显示出缺陷。BearLLM、DCGAN、QSCGAN 和 VQVAE 遭受大量的错误接受, 将不期望输入分散到各种故障类别中。相比之下, 具有检测能力的模型 (如 WDSN 和 SHalluDetect) 表现出高度的错误拒绝, 将有效的诊断信号错误分类为不期望输入。该分析直观地证实了 DA-TMLLM 有效地在准确分布内分类和精确




图 5: 所提出的 DA-TMLLM 与基线模型在三种场景下抗幻觉诊断的 ROC 和 PR 曲线对比。

拒绝不期望输入之间进行权衡,从而实现了真正的抗幻觉诊断。


我们将 DA-TMLLM 生成的合成振动信号质量与三个基于增强的基线 (包括 VQVAE、DCGAN 和 QSCGAN) 在域特定数据集的少数类上进行比较。如表 IV 所总结, DA-TMLLM 实现了最低的 RMSE 和最高的 PSNR 与 FSCS。定量而言,相对于每种情况下的次佳表现模型, DA-TMLLM 平均将 RMSE 降低了 86.9%, 同时将平均 PSNR 和 FSCS 提高了 97.1% 和 67.2%, 验证了其数据增强的优越性。这种优越性能归功于我们的条件扩散模型, 它通过引导的渐进去噪过程擅长捕获复杂的非平稳信号特征。相比之下, DCGAN 和 QSCGAN 容易出现训练不稳定性, 导致对真实数据分布的捕获不完整, 而 VQVAE 倾向于生成过于平滑、缺乏关键高频细节的信号。

C. 消融研究


我们进行消融研究以量化 DA-TMLLM 每个主要组件的贡献。如表 V 所示, 报告了三个场景中消融研究的实验结果, 包括 DS-ACC、G-ACC、AUROC、FAR@95 和 AUPR。

1) 去除 *ControlNet*: 我们将 *ControlNet* 模块替换为大核深度卷积神经网络, 从而移除条件引导, 将模型恢复为传统的去噪扩散概率模型。该变体在所有三个场景中都表现出性能下降, 表明 *ControlNet* 对于从各种故障类型和工况的振动信号中提取判别特征至关重要。


2) 去除 *CGCDM*: 我们移除所提出的 *ControlNet* 引导跨数据集条件扩散模块, 仅使用原始的、不平衡的故障信号训练诊断模型。这导致诊断准确率下降。这一发现突显了我们基于扩散的故障模式增强的有效性, 强调了其在缓解统计偏差和纠正数据不平衡造成的扭曲决策边界方面的作用。




(a) BearLLM




(b) DCGAN




(c) QSCGAN




(d) VQVAE




(e) MLMM




(f) WDSN




(g) MDCC




(h) LLM-Check




(i) MIND



(j) SHalluDetect



(k) LLM-OOD



(1) DA-TMLLM

图 6: DA-TMLLM 与基线模型在场景 3 中抗幻觉诊断的扩展混淆矩阵对比。

表 IV: 基于增强的基线与 DE-TMLLM 的生成质量对比¹

模型	VQVAE			DCGAN			QSCGAN			DA-TMLLM		
指标	RMSE	PSNR	FSCS	RMSE	PSNR	FSCS	RMSE	PSNR	FSCS	RMSE	PSNR	FSCS
IMS_MiIR ²	0.1674	15.5231	0.0621	<u>0.0699</u>	<u>23.1205</u>	<u>0.4791</u>	0.1387	17.1660	0.4396	0.0084	41.5342	0.9811
IMS_SB	0.4097	7.7508	0.0460	<u>0.1696</u>	<u>15.4120</u>	<u>0.4823</u>	0.2251	12.9531	0.3099	0.0217	33.3997	0.7835
IMS_SOR	0.7853	2.0990	0.0239	<u>0.1258</u>	<u>18.1025</u>	<u>0.5693</u>	0.1892	14.4668	0.4196	0.0111	39.1883	0.7418
PU_MiIR	0.2666	11.4819	0.0355	<u>0.0598</u>	<u>24.4715</u>	<u>0.4209</u>	0.1682	15.4824	0.2256	0.0108	39.3536	0.7332
XJTU_MiIR	0.1269	17.9312	0.0408	<u>0.1177</u>	<u>18.6033</u>	<u>0.6004</u>	0.1902	14.4202	0.4533	0.0158	36.1506	0.6809
XJTU_SIR	<u>0.0464</u>	<u>26.6663</u>	0.0912	0.1665	15.7207	<u>0.3842</u>	0.2041	13.8345	0.3467	0.0117	38.9643	0.5786
XJTU_MiB	0.1729	15.2460	0.0865	0.1685	15.4795	0.5216	<u>0.1541</u>	<u>16.2510</u>	<u>0.5346</u>	0.0163	35.8361	0.7601
XJTU_SB	0.4908	6.1818	0.0256	<u>0.1007</u>	<u>20.0536</u>	<u>0.4464</u>	0.2295	12.8102	0.3242	0.0099	40.0970	0.7360
XJTU_SOR	0.3577	8.9290	0.0407	<u>0.1464</u>	<u>16.6960</u>	<u>0.2624</u>	0.1865	14.5998	0.3848	0.0102	39.9638	0.6873

¹ 最佳结果: **粗体**; 次佳结果: 下划线。

² IMS_MiIR 表示对 IMS 数据集中的 MiIR 类别应用数据增强。




图 7: DA-TMLLM 性能对扩散噪声调度器、诊断信号长度、LoRA 微调秩和校准系数的超参数敏感性分析。

3) 去除 *KTURS*: 我们将所提出的 token 级不确定性 (如式(18)所定义) 替换为式(17)中的归一化能量分数。我们观察到不期望输入识别性能下降, 如 AUROC、FAR@95 和 AUPR 所衡量。这一结果证明了设计的关键 token 不确定性重加权策略对检测序列级幻觉的有效性。

4) 去除 *TMLLM*: 我们移除可信多模态大语言模块, 从而消除了框架的幻觉检测能力, 导致不期望输入识别性能下降。这一结果证实了所提出的方法能够有效量化不确定性并提供可信的诊断回答。

D. 超参数敏感性分析

为评估 DA-TMLLM 性能对其超参数的敏感性, 我们在 MBHM、MaFaulDa 和 UP 数据集上进行了分析。该实验研究了扩散模型的噪声调度器 ζ 、诊断信号长度 L_f 、LoRA 微调秩 r_{LoRA} 和关键 token 校准系数 ω 的影响。这些参数的影响分别通过生成信号与真实信号之间的 RMSE、ControlNet 在已知类别上的诊断准确率、最终微调轮次的二元交叉熵损失和不期望输入的检测率来评估。

1) ζ 的影响: 我们评估了线性、余弦和 Sigmoid 噪声调度器, 发现线性方法在大多数故障类型上产生了更优的信号重建, 如图 7 所示。其均匀的噪声添加更好地与故障信号重建的归纳偏差对齐, 而非线性调度器可能

表 V: 三种场景下消融研究的实验结果¹

场景	场景 1					场景 2					场景 3				
指标	DS-ACC	G-ACC	AUROC	FAR@95	AUPR	DS-ACC	G-ACC	AUROC	FAR@95	AUPR	DS-ACC	G-ACC	AUROC	FAR@95	AUPR
去除 ControlNet ²	<u>89.17%</u>	89.74%	1.0000	0.0000	1.0000	<u>89.17%</u>	89.74%	1.0000	0.0000	1.0000	<u>89.17%</u>	90.48%	1.0000	0.0000	1.0000
去除 CGCDM ⁴	87.50%	88.21%	1.0000	0.0000	1.0000	87.50%	88.21%	1.0000	0.0000	1.0000	87.50%	89.05%	1.0000	0.0000	1.0000
去除 KTURS ³	92.78%	<u>92.05%</u>	<u>0.9284</u>	<u>0.5222</u>	<u>0.6579</u>	92.78%	<u>91.54%</u>	0.9251	0.2861	0.7205	92.78%	<u>91.19%</u>	0.9268	<u>0.2861</u>	0.7773
去除 TMLLM ⁵	92.78%	85.64%	0.7073	1.0000	0.1895	92.78%	85.64%	0.8625	0.6306	0.3898	92.78%	79.52%	0.7851	1.0000	0.4210
DA-TMLLM	92.78%	93.33%	1.0000	0.0000	1.0000	92.78%	92.82%	<u>0.9860</u>	<u>0.0028</u>	<u>0.9092</u>	92.78%	93.57%	<u>0.9942</u>	0.0000	<u>0.9887</u>

¹ 最佳结果: **粗体**; 次佳结果: 下划线。

² 去除 ControlNet 表示在消融研究中移除 ControlNet。

³ 去除 KTURS 表示在消融研究中移除 KTURS。

⁴ 去除 CGCDM 表示在消融研究中移除抗幻觉方案中的 CGCDM。

⁵ 去除 TMLLM 表示在消融研究中移除抗幻觉方案中的 TMLLM。

损害生成稳定性。

V. 结论

2) L_f 的影响: 我们通过测试 {960, 1200, 1600, 2400, 4800} 中的值来研究诊断信号长度对 DA-TMLLM 性能的影响。如图 7 所示, 诊断准确率随信号长度增加而提高。较短的信号缺乏足够的判别信息, 而过长的信号可能在扩散过程中造成 GPU 内存瓶颈。因此, 我们选择 $L_f = 2400$ 以平衡诊断效能和计算开销。

3) r_{LoRA} 的影响: 由于 LoRA 设置会影响微调期间的文本-信号对对齐, 我们针对值投影 (v_proj)、查询投影 (q_proj) 和所有线性层 (all_linear) 进行了实验。这些模块的可训练参数分别占模型总数的 0.0130%、0.0223% 和 0.300%。我们从 {1, 2, 4, 8, 16} 中选择 LoRA 秩 r_{LoRA} 。如图 7 所示, 文本-信号对齐性能随可训练参数数量和 LoRA 秩的增加而提高。当针对所有线性层且 $r_{LoRA} = 4$ 时, 达到了最低损失 0.0240, 与表 II 中的最优参数一致。

4) ω 的影响: 我们在范围 {1, 2, ..., 50} 内评估不确定性校准系数 ω 对不期望输入检测的影响。如图 7 所示, 较大的系数增强了 DA-TMLLM 检测不期望 token 的能力。这是因为它更准确地量化了无偏 token 级不确定性, 从而放大了域特定 token 和不期望 token 之间的分布差异。

在本文中, 我们提出了 DA-TMLLM, 一种检测和缓解诊断 LLM 幻觉的新方法。首先, 我们设计了一个 ControlNet 引导的跨数据集条件扩散模型, 通过注入可控语义引导和合成多样化样本来缓解统计偏差。其次, 我们设计了 TMLLM, 通过点二列相关分析和显著性检验来定位关键 token, 并设计关键 token 驱动的不确定性重加权策略, 以增强幻觉检测性能。第三, 我们设计了一个抗幻觉方案, 将基于扩散的增强和 TMLLM 整合到一个统一的流程中, 用于幻觉检测和缓解。在十一个故障诊断数据集上获得的评估结果表明, DA-TMLLM 在八个指标上始终优于十一个对比模型。

参考文献

- [1] C. Lessmeier, J. Kimotho, D. Zimmer, and W. Sextro, "Condition Monitoring of Bearing Damage in Electromechanical Drive Systems by Using Motor Current Signals of Electric Motors: A Benchmark Data Set for Data-Driven Classification," in *Proc. ECPHM*, Bilbao, Spain, 2016.
- [2] S. Lin, Y. Yu, Z. Liang, and Q. Liu, "Cross-domain bearing fault diagnosis via time-frequency feature fusion of acoustic emission signals," pp. 1–33, May 2025, *SSRN: dx.doi.org/10.2139/ssrn.5266786*.
- [3] Y. Bi, R. Fu, C. Jiang, G. Han, Z. Yin, L. Zhao, and Q. Li, "Single-source cross-domain bearing fault diagnosis via multipseudo-domain-augmented adversarial domain-invariant learning," *IEEE Internet Things J.*, vol. 11, no. 19, pp. 31 521–31 533, Oct. 2024.

- [4] L. Hou, H. Yi, Y. Jin, M. Gui, L. Sui, J. Zhang, and Y. Chen, "Inter-shaft bearing fault diagnosis based on aero-engine system: A benchmarking dataset study," *J. Dyn. Monit. Diagn.*, vol. 2, no. 4, p. 228–242, Aug. 2023.
- [5] H. Peng, J. Liu, J. Du, J. Gao, and W. Wang, "BearLLM: A prior knowledge-enhanced bearing health management framework with unified vibration signal representation," in *Proc. AAAI Conf. Artif. Intell.*, vol. 39, PA, United States, Apr. 2025, pp. 19866–19874.
- [6] J. Li, X. Cheng, X. Zhao, J.-Y. Nie, and J.-R. Wen, "HaluEval: A large-scale hallucination evaluation benchmark for large language models," in *Proc. EMNLP*, Singapore, Dec. 2023, pp. 6449–6464.
- [7] A. Azaria and T. Mitchell, "The internal state of an LLM knows when it's lying," in *Proc. EMNLP*, Singapore, Dec. 2023, pp. 967–976.
- [8] X. Liu, J. Chen, J. Xie, and Y. Chang, "Generating HSR bogie vibration signals via pulse voltage-guided conditional diffusion model," *IEEE Trans. Intell. Transp. Syst.*, vol. 26, no. 1, pp. 116–127, Jan. 2025.
- [9] K. Zhou, E. Diehl, and J. Tang, "Deep convolutional generative adversarial network with semi-supervised learning enabled physics elucidation for extended gear fault diagnosis under data limitations," *Mech. Syst. Signal Proc.*, vol. 185, p. 109772, Feb. 2023.
- [10] T. Han, Y.-F. Li, and M. Qian, "A Hybrid Generalization Network for Intelligent Fault Diagnosis of Rotating Machinery under Unseen Working Conditions," *IEEE Trans. Instrum. Meas.*, vol. 70, pp. 1–11, Jun. 2021, Art. no. 3520011.
- [11] M.-H. Vu, V.-Q. Nguyen, T.-T. Tran, V.-T. Pham, and M.-T. Lo, "Few-shot bearing fault diagnosis via ensembling Transformer-based model with Mahalanobis distance metric learning from multiscale features," *IEEE Trans. Instrum. Meas.*, vol. 73, pp. 1–18, Mar. 2024, Art. no. 2513618.
- [12] W. Wan, S. He, J. Chen, A. Li, and Y. Feng, "QSCGAN: An unsupervised quick self-attention convolutional gan for LRE bearing fault diagnosis under limited label-lacked data," *IEEE Trans. Instrum. Meas.*, vol. 70, pp. 1–16, Nov. 2021, Art. no. 3527816.
- [13] Q. Zheng, P. Teng, K. Zhang, G. Ding, X. Lai, Z. Li, and Z. Yuan, "A generalized network with domain invariance and specificity representation for bearing remaining useful life prediction under unknown conditions," *Knowl.-Based Syst.*, vol. 310, p. 112915, Feb. 2025.
- [14] C. Zhao and W. Shen, "Adaptive open set domain generalization network: Learning to diagnose unknown faults under unknown working conditions," *Reliab. Eng. Syst. Saf.*, vol. 226, p. 108672, Oct. 2022.
- [15] Z. Zhu, G. Chen, and G. Tang, "Domain adaptation with multi-adversarial learning for open-set cross-domain intelligent bearing fault diagnosis," *IEEE Trans. Instrum. Meas.*, vol. 72, pp. 1–11, Sept. 2023, Art. no. 3533411.
- [16] J. Long, R. Zhang, Y. Chen, R. Zhao, Z. Yang, Y. Huang, and C. Li, "A customized meta-learning framework for diagnosing new faults from unseen working conditions with few labeled data," *IEEE/ASME Trans. Mechatron.*, vol. 29, no. 2, pp. 1363–1373, Apr. 2024.
- [17] X. Zhang, Y. Zhao, X. Yu, R. Ma, C. Wang, and X. Chen, "Weighted domain separation based open set fault diagnosis," *Reliab. Eng. Syst. Saf.*, vol. 239, p. 109518, Nov. 2023.
- [18] B. Lu, Y. Zhang, Q. Sun, M. Li, and P. Li, "A novel multidomain contrastive-coding-based open-set domain generalization framework for machinery fault diagnosis," *IEEE Trans. Ind. Inform.*, vol. 20, no. 4, pp. 6369–6381, Jan. 2024.
- [19] B. Liu, L.-M. Zhan, Z. Lu, Y. Feng, L. Xue, and X.-M. Wu, "How good are LLMs at out-of-distribution detection?" in *Proc. LREC-COLING*, Torino, Italy, May 2024, pp. 8211 – 8222.
- [20] G. Sriramanan, S. Bharti, V. S. Sadasivan, S. Saha, P. Kattakinda, and S. Feizi, "LLM-Check: Investigating detection of hallucinations in large language models," in *Proc. Adv. Neural Inf. Process. Syst.*, vol. 37, Vancouver, Canada, Dec. 2024.
- [21] J. Duan, H. Cheng, S. Wang, A. Zavalny, C. Wang, R. Xu, B. Kailkhura, and K. Xu, "Shifting attention to relevance: Towards the predictive uncertainty quantification of free-form large language models," in *Proc. Annu. Meet. Assoc. Comput. Linguist.*, vol. 1, Bangkok, Thailand, Aug. 2024, pp. 5050 – 5063.
- [22] T. Zhang, L. Qiu, Q. Guo, C. Deng, Y. Zhang, Z. Zhang, C. Zhou, X. Wang, and L. Fu, "Enhancing uncertainty-based hallucination detection with stronger focus," in *Proc. EMNLP*, Singapore, Dec. 2023, pp. 915 – 932.
- [23] P. Manakul, A. Liusie, and M. Gales, "SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models," in *Proc. EMNLP*, Singapore, Dec. 2023, pp. 9004–9017.
- [24] W. Su, C. Wang, Q. Ai, Y. Hu, Z. Wu, Y. Zhou, and Y. Liu, "Unsupervised real-time hallucination detection based on the internal states of large language models," in *Proc. Annu. Meet. Assoc. Comput. Linguist.*, Hybrid, Bangkok, Thailand, Aug. 2024, pp. 14379 – 14391.
- [25] E. Quevedo, J. Y. Salazar, R. Koerner, P. Rivas, and T. Cerny, "Detecting hallucinations in large language model generation: A token probability approach," in *Proc. ICAI*, Las Vegas, NV, United States, May 2025, pp. 154–173.
- [26] E. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LORA: Low-rank adaptation of large language models," in *Proc. ICLR*, Virtual, Online, Apr. 2022.
- [27] M. A. Marins, F. M. Ribeiro, S. L. Netto, and E. A. da Silva, "Improved similarity-based modeling for the classification of rotating-machine failures," *J. Frankl. Inst.*, vol. 355, no. 4, pp. 1913–1930, Mar. 2018.
- [28] J. Bai, S. Bai, Y. Chu, Z. Cui, K. Dang, X. Deng, and et al., "Qwen technical report," pp. 1–33, Sep. 2023, *arXiv*: <https://arxiv.org/abs/2309.16609>.
- [29] K. Li, X. Ping, H. Wang, P. Chen, and Y. Cao, "Sequential fuzzy diagnosis method for motor roller bearing in variable operating conditions based on vibration analysis," *Sensors*, vol. 13, no. 6, pp. 8013–8041, 2013.
- [30] W. Smith and R. Randall, "Rolling element bearing diagnostics using the case western reserve university data: A benchmark study," *Mech. Syst. Signal Process.*, vol. 64, pp. 100–131, 2015.
- [31] A. P. Daga, A. Fasana, S. Marchesiello, and L. Garibaldi, "The politecnico di torino rolling bearing test rig: Description and analysis of open access data," *Mech. Syst. Signal Proc.*, vol. 120, pp. 252–273, 2019.
- [32] H. Qiu, J. Lee, J. Lin, and G. Yu, "Wavelet filter-based weak signature detection method and its application on rolling element bearing prognostics," *J. Sound Vib.*, vol. 289, no. 4, pp. 1066–1090, Feb. 2006.

- [33] V. Sinitsin, O. Ibryaeva, V. Sakovskaya, and V. Eremeeva, “Intelligent bearing fault diagnosis method combining mixed input and hybrid CNN-MLP model,” *Mech. Syst. Signal Process.*, vol. 180, p. 109454, 2022.
- [34] B. Wang, Y. Lei, N. Li, and N. Li, “A hybrid prognostics approach for estimating remaining useful life of rolling element bearings,” *IEEE Trans. Reliab.*, vol. 69, no. 1, pp. 401–412, 2020.
- [35] Z. Yu, W. Zhao, S. Gao, and B. He, “Cross-size underwater propeller fault diagnosis via domain adversarial training with spectral attention and multi-task learning,” *Ocean Eng.*, vol. 323, p. 120604, 2025.
- [36] Z. Liu, R. Qiu, Z. Zeng, H. Yoo, D. Zhou, Z. Xu, Y. Zhu, K. Woldemariam, J. He, and H. Tong, “Class-imbalanced graph learning without class rebalancing,” in *Proc. ICML*, vol. 235, Vienna, Austria, Jul. 2024, pp. 31 747–31 772.