

1 第一项研究内容（共三页）：HSSTT 可信 SOH 估计方法

1.1 第 1 页：随机自注意力机制

注意力权重的概率化

将注意力 logits 参数化为 Gumbel-Softmax 分布，使片段关联由确定性权重转化为可采样概率权重，并支持不确定性表征。

$$\tilde{A}^{(j)} \sim \mathcal{G}\left((K^{(j)\top}Q^{(j)})/\tau\right)$$

Gumbel-Softmax 可微采样

通过 Gumbel-Max 采样构造离散注意力选择，并以 Gumbel-Softmax 连续松弛获得可反向传播的随机注意力权重。

$$\begin{aligned} z &= e_{\operatorname{argmax}_i (g_i + \log \pi_i)} \\ g_i &= -\log(-\log u_i), \quad u_i \sim \mathcal{U}(0, 1) \\ \tilde{A}_i^{(j)} &= \frac{\exp((g_i + \log \pi_i)/\tau)}{\sum_{k=1}^T \exp((g_k + \log \pi_k)/\tau)} \end{aligned}$$

与高斯扰动的理论一致性

由高斯变量到 Gumbel 噪声的双射表明，该离散松弛机制与高斯扰动近似同构，从而支撑其不确定性量化合理性。

$$g_i = -\log(-\log(\Phi(\epsilon))), \quad \epsilon \sim \mathcal{N}(0, 1)$$

第 1 页说明: 随机自注意力机制

符号描述

- $Q^{(j)}$ 、 $K^{(j)}$: 第 j 个注意力头的查询矩阵和键矩阵。
- $\tilde{A}^{(j)}$: 随机化后的注意力权重矩阵。
- $\mathcal{G}(\cdot)$: Gumbel-Softmax 分布。
- τ : 温度参数, 控制连续松弛程度。
- π_i : 第 i 个候选片段对应的非归一化注意力参数。
- g_i 、 u_i 、 ϵ : Gumbel 噪声、均匀随机变量和标准高斯随机变量。
- $e_{\arg\max_i(\cdot)}$: 由最大响应位置确定的独热基向量。

公式说明

- 第一组公式把标准注意力权重改写为从 Gumbel-Softmax 分布采样的随机变量。
- 第二组公式说明 Gumbel-Max 的离散选择如何通过连续松弛转化为可微注意力权重。
- 第三组公式说明 Gumbel 噪声可由高斯变量映射得到, 用于支撑该随机机制与常见变分不确定性建模的一致性。

1.2 第 2 页: 层次化随机时空 Transformer

距离敏感注意力校正

将循环间距离映射为注意力重标定系数, 使随机注意力同时刻画片段相关性与退化时间间隔。

$$\hat{R}^{(j)} = \frac{1 + \exp(V^{(j)})}{1 + \exp(V^{(j)} - R^{(j)})}$$

可学习聚类键向量

在可学习质心上重构 Key 表征, 压缩冗余 token 并提升稀疏退化特征的聚合效率。

$$\begin{aligned} Q^{(j)}, K^{(j)}, V^{(j)} &= W_Q^{(j)} X, W_K^{(j)} X, W_V^{(j)} X \\ \hat{A}_C &\sim \mathcal{G}\left((K^{(j)\top} C) / \tau_1\right) \\ \hat{K}^{(j)} &= \hat{A}_C C^\top \end{aligned}$$

距离感知的层次化随机聚合

在聚类 Key 与距离矩阵共同约束下采样注意力权重, 生成兼具时序结构感知与不确定性表征能力的退化特征。

$$\begin{aligned} \hat{A}^{(j)} &\sim \mathcal{G}\left((\sigma(\hat{K}^{(j)\top} Q^{(j)}) * \hat{R}^{(j)}) / \tau_2\right) \\ \hat{H}^{(j)} &= \hat{A}^{(j)} V^{(j)} \\ \widehat{\text{MHA}} &= \text{concat}\left(\hat{H}^{(1)} \hat{H}^{(2)} \dots \hat{H}^{(h)}\right) W_O \end{aligned}$$

第 2 页说明: 层次化随机时空 Transformer

符号描述

- $R^{(j)}$ 、 $\hat{R}^{(j)}$: 第 j 个注意力头的距离矩阵及其重标定结果。
- $V^{(j)}$: 距离重标定函数中的可训练参数。
- X : 输入序列特征。
- $W_Q^{(j)}$ 、 $W_K^{(j)}$ 、 $W_V^{(j)}$: 查询、键、值投影矩阵。
- C : 可学习聚类质心矩阵。
- $\hat{A}_C$ 、 $\hat{K}^{(j)}$: 质心采样权重和聚类后的 Key 表征。
- $\hat{A}^{(j)}$ 、 $\hat{H}^{(j)}$: 层次化随机注意力权重和对应注意力头输出。

公式说明

- 第一组公式将循环距离映射为注意力重标定系数, 用于补充传统位置编码难以表达的真实退化间隔。
- 第二组公式先计算 Q/K/V, 再用可学习质心对 Key 进行聚类重构。
- 第三组公式把聚类 Key、距离矩阵和 Gumbel-Softmax 采样结合, 得到层次化随机多头注意力输出。

1.3 第 3 页: 不确定性标定

误差分解与校准动因

将预测误差展开为系统偏差、采样方差与噪声项, 揭示精度提升并不等价于置信度无偏。

$$\begin{aligned} E\left((y - \hat{f}(X))^2\right) &= \text{Bias}^2(\hat{f}(X)) + \text{Var}(\hat{f}(X)) + \sigma^2 \\ &= \left(E(\hat{f}(X)) - E_{y|X}(f(X))\right)^2 + E\left((E(\hat{f}(X)) - \hat{f}(X))^2\right) + \sigma^2 \end{aligned}$$

分布覆盖率校准

以模型赋予真实 SOH 的累计概率为校准样本, 学习单调映射 g 修正预测分布, 使置信度与经验覆盖率一致。

$$\begin{aligned} s_i &= F_i(y_i), \quad \hat{p}(s_i) = \frac{1}{N} \sum_{j=1}^N \mathbb{I}\{F_j(y_j) \leq s_i\} \\ g^* &= \arg \min_{g \in \mathcal{G}_{\text{mono}}} \sum_{i=1}^N (g(s_i) - \hat{p}(s_i))^2 \end{aligned}$$

后验预测与置信估计

从参数后验中采样得到一组预测结果, 并用其均值与标准差分别作为 SOH 点估计和不确定性判据。

$$\begin{aligned} \theta^{(b)} &\sim p(\theta \mid D), \quad y^{(b)} = f_{\theta^{(b)}}(X), \quad b = 1 \dots, B \\ \hat{y} &= \frac{1}{B} \sum_{b=1}^B y^{(b)}, \quad \hat{\sigma} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (y^{(b)} - \hat{y})^2} \end{aligned}$$

第 3 页说明: 不确定性标定

符号描述

- X, y : 输入循环信号和真实 SOH。
- $\hat{f}(X)$: 随机模型的预测函数输出。
- F_i : 第 i 个样本对应的预测 CDF。
- s_i : 模型赋予真实标签 y_i 的累计概率。
- $\hat{p}(s_i)$: 由校准集计算得到的经验覆盖率。
- g^* : 通过保序回归学习得到的单调校准映射。
- $\theta^{(b)}, y^{(b)}$: 第 b 次后验参数采样及其对应预测值。
- $\hat{y}, \hat{\sigma}$: SOH 点估计和预测不确定性。

公式说明

- 第一组公式说明预测误差由偏差、方差和噪声共同决定, 因此原始随机模型仍可能存在置信度偏差。
- 第二组公式给出校准数据的构造方式, 并用单调映射 g^* 对齐预测概率和经验覆盖率。
- 第三组公式给出推理阶段的 Monte Carlo 估计流程, 均值用于 SOH 估计, 标准差用于不确定性和 OOD 判定。

2 第二项研究内容（共三页）：RODTNet 分布外鲁棒退化建模方法

2.1 第 1 页：基于流形收缩的退化表征提取策略

流形收缩与泛化上界

用信息瓶颈和本征维度约束退化表征，使其兼具标签可预测性和低复杂度流形结构。

$$\min_Z \mathcal{IB} = \min_Z [-\mathcal{I}(Z; Y) + \beta \mathcal{I}(Z; X)] = \min_Z [(1 - \beta) \mathcal{H}(Y | Z) + \beta \mathcal{H}(Z | Y)]$$

$$\Delta_{ST} = \mathbb{E}_S [\|f(z) - y\|_2] - \mathbb{E}_T [\|f(z) - y\|_2] \leq 2KQ(\mathcal{H}(Z | Y))$$

$$\mathcal{H}(Z | Y) \leq \mathbb{E}_{y_i \sim \mathcal{Y}} \left[-\log(\epsilon) \text{IntDim}(\mathcal{M}_i) + \log \frac{K'}{C(\epsilon)} \right]$$

Mamba 退化特征编码

用门控残差结构和状态空间递推建模重构信号的长程退化依赖，获得紧凑连续的潜在表征。

$$Z_{MRB}^B = \text{SiLU}(\text{Linear}(\tilde{X}_{Emb})), \quad Z_{MRB}^M = \text{SSM}(\text{SiLU}(\text{Conv}(\text{Linear}(\tilde{X}_{Emb})))), \quad Z_{MRB} = \text{Linear}(Z_{MRB}^M \odot Z_{MRB}^B) + \tilde{X}_{Emb}$$

$$h_t = \bar{A}h_{t-1} + \bar{B}\tilde{x}_t, \quad \bar{A} = DR_A(\Delta, A) = \exp(\Delta A), \quad \bar{B} = DR_B(\Delta, A, B) = (\Delta A)^{-1}(\exp(\Delta A) - I) \cdot \Delta B$$

无偏重构约束

通过信号重构削弱域变量引入的伪相关，使退化表征在给定标签条件下趋于跨域不变。

$$P(Z | Y, D) \neq P(Z | Y)$$

$$Z \perp\!\!\!\perp D | Y$$

第 4 页说明：基于流形收缩的退化表征提取策略

符号描述

- Z 、 Y 、 X ：潜在退化表征、退化标签和原始输入。
- $\mathcal{I}(\cdot; \cdot)$ 、 $\mathcal{H}(\cdot | \cdot)$ ：互信息和条件熵。
- Δ_{ST} ：源域与目标域之间的泛化误差差异。
- $\text{IntDim}(\mathcal{M}_i)$ ：条件退化流形的本征维度。
- Z_{MRB} ：Mamba 残差块输出的退化特征。
- h_t 、 $\bar{A}$ 、 $\bar{B}$ ：状态空间模型的隐藏状态和离散化参数。
- D ：域变量。

公式说明

- 第一组公式说明低条件熵和低本征维度有助于收紧 OOD 泛化误差上界。
- 第二组公式给出 Mamba 残差块与状态空间递推，负责提取长程退化特征。
- 第三组公式说明原始表征存在域偏置，目标是通过重构获得给定退化标签下的域无关表征。

2.2 第 2 页：不确定性驱动的退化特征合成策略

退化特征统计建模

将退化特征的批次均值和标准差建模为 Gaussian 随机变量，为特征分布外推提供概率基础。

$$\mu_Z \sim \mathcal{N}(\mu, \Sigma_\mu^2), \quad \sigma_Z \sim \mathcal{N}(\sigma, \Sigma_\sigma^2)$$

$$\mu = \frac{1}{HE} \sum_H \sum_E Z_{MRB}, \quad \sigma = \sqrt{\frac{1}{HE} \sum_H \sum_E (Z_{MRB} - \mu)^2}$$

域漂移不确定性量化

用批次内统计量变异性估计均值和标准差的不确定性，刻画潜在域漂移幅度。

$$\Sigma_\mu^2 = \frac{1}{B} \sum_{b \in B} (\mu - \mathbb{E}_b(\mu))^2, \quad \Sigma_\sigma^2 = \frac{1}{B} \sum_{b \in B} (\sigma - \mathbb{E}_b(\sigma))^2$$

重参数化特征合成

通过重参数化采样生成新的统计量，并据此对退化特征执行分布外扩张。

$$\mu'_Z = \epsilon_\mu \Sigma_\mu + \mu, \quad \epsilon_\mu \sim \mathcal{N}(0, 1), \quad \sigma'_Z = \epsilon_\sigma \Sigma_\sigma + \sigma, \quad \epsilon_\sigma \sim \mathcal{N}(0, 1)$$

$$G(Z_{MRB}) = \sigma'_Z \left(\frac{Z_{MRB} - \mu}{\sigma} \right) + \mu'_Z$$

第 5 页说明: 不确定性驱动的退化特征合成策略

符号描述

- Z_{MRB} : Mamba 编码器输出的退化特征张量。
- μ_Z 、 σ_Z : 退化特征统计量的随机变量。
- μ 、 σ : 当前批次退化特征的经验均值和标准差。
- Σ_μ^2 、 Σ_σ^2 : 特征均值和标准差的统计不确定性。
- ϵ_μ 、 ϵ_σ : 标准 Gaussian 采样噪声。
- $G(Z_{MRB})$: UDFS 合成后的退化特征。

公式说明

- 第一组公式将退化特征统计量建模为 Gaussian 分布。
- 第二组公式用批次内变异性估计统计量不确定性, 对应域漂移可能引发的分布变化。
- 第三组公式通过重参数化生成新统计量, 并对原始特征执行标准化-重缩放式合成。

2.3 第 3 页: 感知长尾分布的自适应重平衡微调策略

分箱退化统计量估计

将连续 SOH 标签离散为分箱, 并分别估计每个分箱内的局部退化特征统计量。

$$\mu_b = \frac{1}{HE} \sum_H \sum_E Z_{MRB}, \quad \sigma_b = \sqrt{\frac{1}{HE} \sum_H \sum_E (Z_{MRB} - \mu)^2}$$

标签邻近核平滑

基于 SOH 标签的物理邻近度在相邻分箱间传递统计信息, 校正尾部分箱的稀疏偏置。

$$\tilde{\mu}_b = \sum_{1 \leq b, b' \leq \mathcal{B}} \exp(-\gamma \|y_b - y_{b'}\|_2) \mu_{b'}, \quad \tilde{\sigma}_b = \sum_{1 \leq b, b' \leq \mathcal{B}} \exp(-\gamma \|y_b - y_{b'}\|_2) \sigma_{b'}$$

重平衡变换与统计更新

用校正统计量重构特征分布, 并通过动量滑动平均稳定训练过程。

$$\tilde{G}(Z_{MRB}) = \tilde{\sigma}_b \left(\frac{G(Z_{MRB}) - \mu_b}{\sigma_b} \right) + \tilde{\mu}_b$$

$$\mu_b^{(i)} \leftarrow \alpha \mu_b^{(i-1)} + (1 - \alpha) \mu_b, \quad \sigma_b^{(i)} \leftarrow \alpha \sigma_b^{(i-1)} + (1 - \alpha) \sigma_b$$

第 6 页说明：感知长尾分布的自适应重平衡微调策略

符号描述

- b, b' : SOH 标签分箱索引。
- μ_b, σ_b : 第 b 个分箱内退化特征的均值和标准差。
- $\tilde{\mu}_b, \tilde{\sigma}_b$: 经标签邻近核平滑后的校正统计量。
- $y_b, y_{b'}$: 对应分箱的 SOH 标签代表值。
- γ : Gaussian 核平滑系数。
- $\tilde{G}(Z_{MRB})$: LARR 校正后的退化特征。
- α : 动量更新系数。

公式说明

- 第一组公式估计每个 SOH 分箱内部的局部特征统计量。
- 第二组公式利用标签邻近度聚合相邻分箱信息，缓解尾部样本稀疏导致的统计偏置。
- 第三组公式将 UDFS 输出特征校正到平衡统计分布，并用动量机制稳定统计量更新。

3 第三项研究内容（共三页）：DA-TMLLM 抗幻觉故障诊断方法

3.1 第 1 页：ControlNet 引导的跨数据集条件扩散模型

跨数据集信号标准化

用固定时长分段、频域长度对齐和尺度归一化，将异构振动信号转换为统一输入。

$$\begin{aligned} \mathbf{x}_o^{(m)} &= [x_r[m\nu], x_r[m\nu + 1], \dots, x_r[(m+1)\nu - 1]]^\top \\ \mathbf{x}_v &= \begin{cases} \text{SNorm}(\text{DFCT}(\mathbf{x}_o)[0 : L_f - 1]), & \ell \geq L_f \\ \text{SNorm}(\text{Concat}(\text{DFCT}(\mathbf{x}_o), \mathbf{0}_{L_f - \ell})), & \ell < L_f \end{cases}, \quad \text{SNorm}(\mathbf{x}) = g \frac{\mathbf{x}}{\|\mathbf{x}\|_2 + \varepsilon} \end{aligned}$$

条件扩散生成过程

通过前向加噪和条件反向去噪，生成服从目标故障语义分布的合成振动信号。

$$q(\mathbf{x}_v^{(s)} | \mathbf{x}_v^{(s-1)}) = \mathcal{N}\left(\sqrt{\alpha^{(s)}}\mathbf{x}_v^{(s-1)}, (1 - \alpha^{(s)})\mathbf{I}\right), \quad q(\mathbf{x}_v^{(S)} | \mathbf{x}_v^{(0)}) = \mathcal{N}\left(\sqrt{\hat{\alpha}^{(S)}}\mathbf{x}_v^{(0)}, (1 - \hat{\alpha}^{(S)})\mathbf{I}\right), \quad \mu_{\theta_d}(\bar{\mathbf{x}}_v^{(s)}, s, \mathbf{c}) = \frac{\bar{\mathbf{x}}_v^{(s)} - \sigma^{(s)}\epsilon_{\theta_d}(\bar{\mathbf{x}}_v^{(s)}, s, \mathbf{c})}{\sqrt{\hat{\alpha}^{(s)}}}$$

ControlNet 语义注入与鲁棒损失

用 ControlNet 条件向量通过多头注意力引导扩散生成，并以 Huber 损失约束去噪残差。

$$\begin{aligned} \mathbf{H}_v &= [\mathbf{x}_v, \tilde{\mathbf{x}}_v, \mathbf{x}_{vr}] \in \mathbb{R}^{3 \times L_f}, \quad \mathbf{x}_{vr} = \mathbf{x}_v - \tilde{\mathbf{x}}_v \\ \mathbf{Q}^{(s)} &= \mathbf{W}_Q \tilde{\mathbf{x}}_v^{(s)}, \quad \mathbf{K}^{(s)} = \mathbf{W}_K \tau(\mathbf{c}), \quad \mathbf{V}^{(s)} = \mathbf{W}_V \tau(\mathbf{c}) \\ \mathbf{A}^{(s)} &= \text{Softmax}\left(\frac{\mathbf{Q}^{(s)}(\mathbf{K}^{(s)})^\top}{\sqrt{d_k}}\right) \mathbf{V}^{(s)}, \quad \text{MHA}(\bar{\mathbf{x}}_v^{(s)}, \mathbf{c}) = \mathbf{W}_o[\mathbf{A}_1^{(s)}; \dots; \mathbf{A}_{N_h}^{(s)}] \\ L^{(s)} &= \mathbb{E}_{s \sim [1, S], \mathbf{x}_v^{(s)}, \epsilon^{(s)}} [\text{Huber}(r^{(s)})], \quad r^{(s)} = \|\epsilon^{(s)} - \epsilon_{\theta_d}(\bar{\mathbf{x}}_v^{(s)}, s, \mathbf{c})\|_2, \quad \text{Huber}(r^{(s)}) = \begin{cases} \frac{1}{2}(r^{(s)})^2, & r^{(s)} < \lambda \\ \lambda(r^{(s)} - \frac{\lambda}{2}), & \text{otherwise} \end{cases} \end{aligned}$$

第 7 页说明：ControlNet 引导的跨数据集条件扩散模型

符号描述

- $\mathbf{x}_o^{(m)}$ 、 $\mathbf{x}_v$: 原始分段信号和标准化后的振动信号。
- ν 、 L_f 、 ℓ : 采样率、预设频域长度和实际谱系数长度。
- $q(\cdot)$: 扩散前向条件分布。
- $\alpha^{(s)}$ 、 $\hat{\alpha}^{(S)}$: 单步和累积噪声缩放系数。
- ϵ_{θ_d} : 噪声预测网络。
- $\mathbf{c}$: ControlNet 提供的条件向量。
- $\mathbf{H}_v$: ControlNet 三元组输入。
- $L^{(s)}$ 、 $r^{(s)}$ 、 λ : Huber 去噪训练目标、噪声预测残差和分段阈值。

公式说明

- 第一组公式完成跨数据集输入标准化，减少采样率和幅值差异。
- 第二组公式描述扩散模型的前向加噪和条件反向去噪过程。
- 第三组公式说明 ControlNet 条件如何注入去噪网络，并通过 Huber 损失鲁棒约束噪声预测残差。

3.2 第 2 页: 可信多模态大语言模型

文本-信号对齐输入

将振动信号编码特征和故障文本 token 特征对齐为可输入大语言模型的多模态提示。

$$\begin{aligned} \mathbf{H}_g &= [\mathbf{x}_g, \tilde{\mathbf{x}}_g, \mathbf{x}_{gr}] \in \mathbb{R}^{3 \times L_f}, \quad \mathbf{x}_{gr} = \mathbf{x}_g - \tilde{\mathbf{x}}_g, \quad \mathbf{M}_g = \{\mathbf{H}_g, \mathbf{T}\}, \quad \mathbf{E} = \text{Emb}(\text{Tok}(\mathbf{D})) \in \mathbb{R}^{\gamma \times N_c \times h} \\ \boldsymbol{\theta}_{l_3} &= \text{reshape}(\mathbf{E}, (\gamma, N_c h)), \quad \boldsymbol{\theta}_{\text{ts}} = \{\boldsymbol{\theta}_{l_1}, \boldsymbol{\theta}_{l_2}, \boldsymbol{\theta}_{l_3}\} \end{aligned}$$

Token 概率与能量

将自回归生成概率转化为 token 级 NLL 能量, 用于表征回答局部不确定性。

$$P(\text{Token}_k = w \mid \text{Token}_{<k}) = \frac{\exp(\text{Proj}(\mathbf{a}_k)_w)}{\sum_{w' \in \mathcal{V}} \exp(\text{Proj}(\mathbf{a}_k)_{w'})}, \quad \text{NLL}(\text{Token}_k = w) = -\log \frac{\exp(\text{Proj}(\mathbf{a}_k)_w)}{\sum_{w' \in \mathcal{V}} \exp(\text{Proj}(\mathbf{a}_k)_{w'})}$$

关键 Token 统计定位

用点二列相关和显著性检验识别对非预期输入最敏感的关键 token 位置。

$$\begin{aligned} r_{pb} &= \frac{\mu_{nor} - \mu_{un}}{\sigma_{total}} \sqrt{\frac{N_{nor} N_{un}}{(N_{nor} + N_{un})^2}} \\ t &= r_{pb} \sqrt{\frac{(N_{nor} + N_{un}) - 2}{1 - r_{pb}^2}}, \quad df = (N_{nor} + N_{un}) - 2 \\ p_{\text{two-sided}} &= 2 [1 - F_{t_{df}}(|t|)] \end{aligned}$$

第 8 页说明: 可信多模态大语言模型

符号描述

- H_g 、 M_g : 信号三元组输入和多模态输入。
- D 、 E : 故障文本描述集合及其 token 嵌入。
- θ_{ts} : 文本-信号对齐模块参数。
- $Token_k$: 生成序列中的第 k 个 token。
- a_k : 第 k 个生成位置的隐藏状态。
- $\mathcal{V}$: 大语言模型词表。
- r_{pb} 、 t 、 $p_{\text{two-sided}}$: 点二列相关系数、显著性统计量和双侧检验概率。

公式说明

- 第一组公式描述信号特征、文本 token 特征和对齐模块参数的构造。
- 第二组公式把自回归 token 概率转化为 NLL 能量, 作为局部不确定性指标。
- 第三组公式通过统计相关性和显著性检验选择关键 token。

3.3 第 3 页: 基于 DA-TMLLM 的抗幻觉故障诊断

Token 级能量归一化

将生成序列中每个 token 的 NLL 归一化, 形成可比较的 token 级不确定性分布。

$$\hat{\mathbf{y}}_g = \{Token_1, Token_2, \dots, Token_{N_t}\}$$

$$NLL_k = -\log P(Token_k | Token_{<k}), \quad \tilde{NLL}_k = NLL_k / \sum_{j=1}^{N_t} NLL_j, \quad \widetilde{NLL}(Token_k) = \frac{NLL(Token_k)}{\sum_{j=1}^{N_t} NLL(Token_j)}$$

关键 Token 不确定性重加权

对关键 token 位置赋予相关性驱动的额外权重, 使局部幻觉迹象在序列级分数中被放大。

$$UT(Token_k; \omega, r_{pb}) = [1 + (\omega r_{pb} - 1) \mathbb{I}_{\{k=\delta-1\}}] \widetilde{NLL}(Token_k)$$

$$UA(\hat{\mathbf{y}}_g) = \sum_{k=1}^{N_t} [1 + (\omega r_{pb} - 1) \mathbb{I}_{\{k=\delta-1\}}] \widetilde{NLL}(Token_k)$$

序列级幻觉判定

用正常验证集得到的置信区间作为接受域, 超出区间的回答被判定为存在幻觉风险。

$$\psi_{lower} = \mu_{val} - \sigma_{val}, \quad \psi_{upper} = \mu_{val} + \sigma_{val}, \quad UA(\hat{\mathbf{y}}_{test}) \notin [\psi_{lower}, \psi_{upper}]$$

第 9 页说明：基于 DA-TMLLM 的抗幻觉故障诊断

符号描述

- $\hat{y}_g$: 大语言模型生成的诊断回答 token 序列。
- N_t : 生成序列长度。
- NLL_k 、 $\widetilde{NLL}$: token 能量及其归一化结果。
- UT: 关键 token 重加权后的 token 级不确定性。
- UA: 序列级不确定性分数。
- $\delta - 1$: 统计检验确定的关键 token 位置。
- ω : 关键 token 权重放大系数。
- ψ_{lower} 、 ψ_{upper} : 正常验证集确定的不确定性接受区间。

公式说明

- 第一组公式把 token 能量归一化为序列内可比较的不确定性分布。
- 第二组公式对关键 token 位置加权，并聚合得到序列级幻觉风险分数。
- 第三组公式用正常样本验证集构造接受区间，超出区间则触发拒识或复核。